

Analisi EEG per la classificazione ADHD vs Control

Noemi Aime

26 giugno 2026

Indice

1	Introduzione	2
2	Metodi	2
2.1	Dataset	2
2.2	Feature extraction	3
2.3	Esplorazione delle feature	4
2.3.1	Test di Mann-Whitney U	4
2.3.2	Cohen's d	5
2.3.3	Correzione per confronti multipli	5
2.3.4	Analisi di correlazione	6
2.4	Classificazione con Random Forest	6
2.4.1	Tuning degli iperparametri	7
2.4.2	Feature importance	8
3	Risultati	8
3.1	Differenze tra gruppi ed effect size	8
3.2	Feature significative dopo correzione FDR	10
3.3	Correlazione tra feature	12
3.3.1	Correlazioni canale-livello	13
3.3.2	Correlazioni regionali	13
3.3.3	Distribuzione delle correlazioni	14
3.4	Classificazione Random Forest	16
3.5	Performance del modello finale	17
3.6	Feature importance	19
3.7	Riduzione del feature set in base alla correlazione	21
3.8	Studio feature theta/beta ratio	24

1 Introduzione

Il disturbo da deficit di attenzione e iperattività (ADHD) è un disturbo del neurosviluppo caratterizzato da sintomi di disattenzione, impulsività e iperattività. Questo può influire sulle capacità attentive, il controllo cognitivo e il comportamento durante compiti che richiedono concentrazione e risposta a stimoli esterni.

L'elettroencefalografia (EEG) risulta uno strumento utile per studiare l'attività cerebrale associata a questi processi, permette infatti di registrare l'attività elettrica cerebrale con elevata risoluzione temporale. I segnali EEG sono costituiti da serie temporali misurate da elettrodi posizionati sullo scalpo secondo configurazioni standard, come il sistema internazionale 10–20. Attraverso l'analisi di tali segnali è possibile estrarre informazioni sull'attività cerebrale in diverse bande di frequenza, come delta, theta, alpha e beta.

Un indice molto studiato è il rapporto theta/beta, o theta/beta ratio (TBR). Il TBR è stato proposto come possibile misura quantitativa per distinguere soggetti con ADHD da soggetti di controllo. Tuttavia, il suo ruolo diagnostico è ancora discusso. La meta-analisi di Arns, Conners e Kraemer ha mostrato che, sebbene molti studi abbiano riportato un TBR aumentato nei soggetti con ADHD, gli effect size complessivi presentavano una significativa eterogeneità. Gli autori riportano un effect size medio pari a 0.75 nei soggetti di 6–13 anni e pari a 0.62 nel gruppo 6–18 anni, ma sottolineano che questi valori possono rappresentare una sovrastima a causa dell'eterogeneità tra gli studi [2]. Inoltre, l'analisi post-hoc evidenzia una riduzione della differenza di TBR tra ADHD e controlli nel corso degli anni, principalmente associata a un aumento del TBR nei gruppi di controllo [2].

Per questo motivo, Arns et al. concludono che un TBR elevato non può essere considerato una misura diagnostica affidabile per l'ADHD, pur potendo avere valore prognostico in un sottogruppo di pazienti [2]. A partire da questa osservazione, il presente lavoro non assume il theta/beta ratio come unico marker diagnostico, ma lo analizza all'interno di una pipeline multifeature.

L'obiettivo del progetto è quindi valutare se feature EEG spettrali possano distinguere soggetti ADHD e Control. In particolare, il lavoro si propone di:

1. confrontare statisticamente le feature EEG tra i due gruppi;
2. valutare le performance di classificazione di un modello Random Forest;
3. analizzare quali feature contribuiscono maggiormente alla classificazione;
4. verificare se le sole feature theta/beta ratio siano sufficienti a ottenere performance comparabili a quelle del modello multifeature.

Poiché il progetto è ancora in fase di completamento, i risultati devono essere considerati preliminari.

2 Metodi

2.1 Dataset

Il dataset utilizzato è disponibile su Kaggl ([1]). Esso contiene registrazioni EEG di 61 bambini con ADHD e 60 soggetti di controllo, di età compresa tra 7 e 12 anni, registrati durante un compito di attenzione visiva in cui si mostra ai bambini immagini di personaggi di cartoni animati. La distribuzione delle classi risulta approssimativamente bilanciata.

I dati sono organizzati in formato tabellare: ogni riga corrisponde a un campione temporale del segnale EEG, mentre le colonne contengono i valori dei canali EEG, l'identificativo del soggetto e la classe diagnostica. Le registrazioni sono state acquisite con frequenza di campionamento $f_s = 128$ Hz.

Il dataset contiene 19 canali EEG:

Fp1, Fp2, F3, F4, C3, C4, P3, P4, O1, O2, F7, F8, T7, T8, P7, P8, Fz, Cz, Pz.

I canali seguono la nomenclatura del sistema internazionale 10-20. È uno standard utilizzato per descrivere la posizione degli elettrodi sullo scalpo in modo riproducibile tra soggetti diversi. In questo sistema la distanza tra gli elettrodi che viene calcolata in percentuali (10% o 20%) rispetto alla lunghezza della testa, misurata in senso fronto-occipitale e laterale. Le lettere dei canali indicano approssimativamente la regione corticale sottostante: **Fp** indica la regione frontopolare, **F** la regione frontale, **C** la regione centrale, **P** la regione parietale, **O** la regione occipitale e **T** la regione temporale. I numeri dispari indicano elettrodi localizzati prevalentemente sull'emisfero sinistro, mentre i numeri pari indicano elettrodi localizzati prevalentemente sull'emisfero destro. Gli elettrodi indicati con la lettera **z**, come **Fz**, **Cz** e **Pz**, si trovano lungo la linea mediana.

Questo raggruppamento consente di analizzare le feature sia a livello di singolo canale sia a livello regionale, confrontando informazioni più localizzate con rappresentazioni più sintetiche dell'attività EEG.

Durante la registrazione non sono presenti variazioni di condizione associate al target e al task. Per questo motivo, le serie temporali EEG sono state trasformate in feature soggetto-livello. In questo modo, ogni soggetto è rappresentato da una singola riga nella tabella finale delle feature.

2.2 Feature extraction

L'estrazione delle feature è stata effettuata a partire dalle serie temporali EEG di ciascun soggetto. Per ogni soggetto e per ogni canale EEG, il segnale temporale è stato trasformato nel dominio della frequenza mediante stima della Power Spectral Density.

La Power Spectral Density, o PSD, descrive come la potenza del segnale è distribuita sulle diverse frequenze. La PSD è stata stimata utilizzando il metodo di Welch ([5]). Tale metodo suddivide il segnale in finestre temporali parzialmente sovrapposte, calcola lo spettro per ciascuna finestra e infine media gli spettri ottenuti.

I parametri utilizzati per il metodo di Welch sono stati:

$$n_{\text{perseg}} = 512, \quad n_{\text{overlap}} = 256$$

Poiché la frequenza di campionamento è pari a 128 Hz, una finestra di 512 campioni corrisponde a $\frac{512}{128} = 4$ s

La risoluzione in frequenza della PSD è quindi $\Delta f = \frac{f_s}{n_{\text{perseg}}} = \frac{128}{512} = 0.25$ Hz.

A partire dalla PSD sono state calcolate le potenze nelle principali bande EEG: delta, theta, alpha e beta. Gli intervalli di frequenza utilizzati sono riportati nella Tabella 1.

Banda EEG	Intervallo di frequenza
Delta (δ)	1–4 Hz
Theta (θ)	4–8 Hz
Alpha (α)	8–12 Hz
Beta (β)	12–30 Hz

Tabella 1: Bande di frequenza utilizzate per il calcolo delle feature spettrali.

La potenza di ciascuna banda è stata calcolata integrando la PSD nell'intervallo di frequenze corrispondente (f_1, f_2) :

$$P_{\text{band}} = \int_{f_1}^{f_2} PSD(f), df \quad (1)$$

In aggiunta alle potenze di banda, è stato calcolato il rapporto tra theta e beta, definito come:

$$TBR = \frac{P_{\theta}}{P_{\beta}} \quad (2)$$

Ogni feature è stato calcolata sia a livello di singolo canale sia a livello regionale mediando le feature dei canali appartenenti alla stessa regione.

L'output finale della feature extraction è una tabella soggetto-livello contenente potenze di banda per ciascun canale, rapporti theta/beta per ciascun canale, potenze medie regionali, rapporti theta/beta regionali e metadati del soggetto, come identificativo, classe e durata della registrazione.

2.3 Esplorazione delle feature

Dopo l'estrazione delle feature, è stata eseguita un'analisi esplorativa per studiare la distribuzione delle variabili e confrontare i due gruppi ADHD e Control.

In primo luogo, sono state calcolate statistiche descrittive per ciascuna feature, tra cui media, deviazione standard, minimo, massimo e quartili. Questa fase ha permesso di osservare la scala delle variabili, la loro variabilità e la possibile presenza di valori estremi.

2.3.1 Test di Mann-Whitney U

Per confrontare ciascuna feature tra soggetti ADHD e soggetti Control è stato utilizzato il test di Mann-Whitney U.

Questo test è un test non parametrico per il confronto tra due gruppi indipendenti ([4]). È stato scelto perché le feature EEG possono non seguire una distribuzione normale e possono contenere outlier. A differenza del test t di Student, il test di Mann-Whitney non confronta direttamente le medie dei due gruppi, ma confronta i ranghi dei valori.

Il procedimento consiste nel considerare insieme tutti i valori della feature nei due gruppi, ordinarli dal più piccolo al più grande e assegnare a ciascun valore un rango. Se i due gruppi provengono dalla stessa distribuzione, i ranghi dovrebbero essere distribuiti in modo simile tra ADHD e Control. Se invece un gruppo tende ad avere valori più alti o più bassi, anche i ranghi tenderanno a essere sistematicamente più alti o più bassi.

Per un gruppo con n_1 osservazioni, la statistica U_1 può essere scritta come:

$$U_1 = R_1 - \frac{n_1(n_1 + 1)}{2} \quad (3)$$

)

dove R_1 è la somma dei ranghi del primo gruppo.

La statistica U finale del test viene calcolata come il valore minimo tra U_1 e la controparte U_2 del secondo gruppo.

Nel presente progetto è stato utilizzato un test a due code, poiché non si è imposto a priori che le feature dovessero essere maggiori nel gruppo ADHD o nel gruppo Control. In questo modo, il test è sensibile a differenze in entrambe le direzioni.

Il p-value ottenuto dal test indica la probabilità di osservare una differenza nei ranghi almeno pari a quella osservata, assumendo vera l'ipotesi nulla. L'ipotesi nulla è che la feature abbia distribuzioni identiche nei due gruppi.

2.3.2 Cohen's d

Oltre alla significatività statistica, è stata calcolata una misura della grandezza dell'effetto tramite Cohen's d .

Il p-value indica se una differenza è statisticamente significativa, ma non descrive direttamente quanto tale differenza sia grande. Per questo motivo, Cohen's d è stato utilizzato per quantificare la differenza standardizzata tra le medie dei due gruppi.

Cohen's d è definito come:

$$d = \frac{\mu_{ADHD} - \mu_{Control}}{s_{pooled}} \quad (4)$$

dove μ_{ADHD} è la media della feature nel gruppo ADHD, $\mu_{Control}$ è la media della feature nel gruppo Control e s_{pooled} è la deviazione standard pooled.

La deviazione standard pooled si definisce come:

$$s_{pooled} = \sqrt{\frac{s_{ADHD}^2 + s_{Control}^2}{2}} \quad (5)$$

dove s_{ADHD} e $s_{Control}$ sono le deviazioni standard nei due gruppi.

Un valore positivo di Cohen's d indica che la feature ha valori medi più alti nel gruppo ADHD, mentre un valore negativo indica valori medi più alti nel gruppo Control. Il valore assoluto di Cohen's d è stato utilizzato per ordinare le feature in base alla grandezza della differenza tra i gruppi.

In questo modo è stato possibile identificare le feature con la maggiore separazione tra ADHD e Control, indipendentemente dalla direzione della differenza.

2.3.3 Correzione per confronti multipli

Poiché il confronto statistico è stato ripetuto su molte feature EEG, è stato necessario correggere i p-value per confronti multipli ([3]).

Eseguendo diversi test statistici aumenta la probabilità di ottenere risultati apparentemente significativi solo per caso. Per ridurre questo rischio è stata utilizzata la procedura Benjamini-Hochberg per il controllo del False Discovery Rate.

Il False Discovery Rate controlla la proporzione attesa di falsi positivi tra le feature dichiarate significative.

La procedura Benjamini-Hochberg ordina i p-value dal più piccolo al più grande:

$$p_{(1)} \leq p_{(2)} \leq \dots \leq p_{(m)} \quad (6)$$

dove m è il numero totale di test eseguiti.

Ogni p-value ordinato viene confrontato con una soglia che dipende dalla sua posizione $\frac{i}{m}Q$ dove i è il rango del p-value ordinato, m è il numero totale di test e Q è il livello di False Discovery Rate scelto.

Nel progetto sono state considerate significative dopo correzione le feature con:

$$p_{FDR} < 0.05$$

2.3.4 Analisi di correlazione

Dopo il confronto tra gruppi, è stata analizzata la correlazione tra tutte le feature EEG numeriche.

Molte feature EEG possono essere correlate tra loro perché derivano dalla stessa banda di frequenza, da canali spazialmente vicini o da rapporti calcolati a partire dalle stesse grandezze.

Per questa analisi è stata utilizzata la correlazione di Spearman, una misura non parametrica di associazione monotona tra due variabili. A differenza della correlazione di Pearson, Spearman non richiede che la relazione tra le variabili sia lineare e non richiede l'assunzione di normalità.

Il coefficiente di Spearman si basa sui ranghi delle osservazioni. Date due variabili X e Y , i valori vengono trasformati nei rispettivi ranghi $R(X)$ e $R(Y)$, e la correlazione viene calcolata sui ranghi.

Nel caso senza ranghi uguali, il coefficiente di Spearman può essere scritto come:

$$\rho = 1 - \frac{6 \sum_{i=1}^n d_i^2}{n(n^2 - 1)} \quad (7)$$

dove d_i è la differenza tra i ranghi delle due variabili per l'osservazione i , e n è il numero di osservazioni.

Il coefficiente ρ varia tra -1 e 1 e $\rho = 1$ indica una relazione monotona positiva perfetta e $\rho = -1$ indica una relazione monotona negativa perfetta, mentre $\rho = 0$ indica assenza di relazione monotona.

2.4 Classificazione con Random Forest

Per valutare se le feature EEG estratte permettono di distinguere soggetti ADHD e Control, è stato utilizzato un classificatore Random Forest.

Prima dell'addestramento, il dataset soggetto-livello è stato diviso in due sottoinsiemi:

- training/validation set, pari all'80
- test set indipendente, pari al 20

La divisione è stata effettuata in modo da mantenere proporzioni simili di soggetti ADHD e Control nei due sottoinsiemi.

Il test set è stato mantenuto separato durante la fase di selezione del modello ed è stato utilizzato solo per la valutazione finale. Questa scelta riduce il rischio di data leakage.

Sul training/validation set è stata eseguita una cross-validation stratificata a 5 fold. In ogni iterazione, il modello è stato addestrato su quattro fold e validato sul fold rimanente. La procedura è stata ripetuta cinque volte, in modo che ogni fold fosse utilizzato una volta come validation set.

Sono stati confrontati tre insiemi di feature:

1. tutte le feature EEG;
2. solo le feature a livello di singolo canale;
3. solo le feature medie regionali.

Questo confronto permette di valutare se la classificazione dipenda maggiormente da informazioni locali a livello di elettrodo, oppure da pattern più globali a livello regionale.

Il classificatore Random Forest presenta diversi iperparametri, vedi Sezione 2.5.1. È stato inoltre utilizzato il parametro `class_weight="balanced"` per compensare eventuali differenze nella distribuzione delle classi.

Le metriche utilizzate per valutare le prestazioni del modello sono state:

- accuracy;
- balanced accuracy;
- precision;
- recall;
- F1-score;
- ROC-AUC;
- confusion matrix.

La balanced accuracy è stata utilizzata come metrica principale per confrontare i feature set.

Dopo il confronto in cross-validation, il miglior feature set è stato selezionato in base alla balanced accuracy media. ì

2.4.1 Tuning degli iperparametri

Il tuning degli iperparametri è stato eseguito sul miglior feature set selezionato nella fase precedente, utilizzando esclusivamente il training/validation set.

L'ottimizzazione degli iperparametri è stata effettuata in due passaggi. È stata inizialmente utilizzata una `RandomizedSearchCV` per esplorare in modo efficiente uno spazio ampio di possibili combinazioni di iperparametri. Successivamente, è stata applicata una `GridSearchCV` locale attorno alla migliore combinazione individuata dalla ricerca randomizzata, con l'obiettivo di raffinare ulteriormente la selezione dei parametri.

Entrambe le fasi di tuning sono state eseguite mediante cross-validation stratificata a 5 fold sul training/validation set. La metrica utilizzata per selezionare la migliore combinazione di iperparametri è stata la balanced accuracy, poiché tiene conto delle performance su entrambe le classi.

Lo spazio di ricerca iniziale utilizzato nella `RandomizedSearchCV` è riportato nella Tabella 2.

Iperparametro	Valori o intervallo testato
<code>n_estimators</code>	interi tra 200 e 1500
<code>max_depth</code>	None, 3, 5, 7, 10, 15, 20, 30
<code>min_samples_leaf</code>	interi tra 1 e 9
<code>min_samples_split</code>	interi tra 2 e 14
<code>max_features</code>	<code>sqrt</code> , <code>log2</code> , None

Tabella 2: Spazio di ricerca degli iperparametri utilizzato nella `RandomizedSearchCV`.

Dopo la ricerca randomizzata, è stata costruita una griglia locale centrata sui migliori valori individuati. Per i parametri numerici sono stati testati valori vicini al valore ottimale trovato dalla `RandomizedSearchCV`; per `max_depth` e `max_features` sono stati mantenuti anche valori alternativi comuni.

Dopo la selezione finale degli iperparametri, il modello Random Forest è stato riaddestrato sull'intero training/validation set e valutato una sola volta sul test set.

2.4.2 Feature importance

Dopo l'addestramento del modello finale, sono stati estratti i valori di feature importance della Random Forest.

La feature importance della Random Forest si basa sulla riduzione media dell'impurità, chiamata anche mean decrease in impurity. In un albero decisionale, ogni nodo viene diviso scegliendo la feature e la soglia che permettono di separare meglio le classi.

Come misura comune dell'impurità si usa la Gini impurity:

$$Gini = 1 - p_{ADHD}^2 - p_{Control}^2 \quad (8)$$

dove p_k è la proporzione di campioni appartenenti alla classe k nel nodo.

La riduzione di impurità prodotta da uno split è calcolata come:

$$\Delta I = I_{parent} \left(\frac{N_{left}}{N_{parent}} I_{left} + \frac{N_{right}}{N_{parent}} I_{right} \right) \quad (9)$$

Una feature viene considerata importante se viene utilizzata in split che riducono fortemente l'impurità. Nella Random Forest, l'importanza viene calcolata mediando il contributo della feature su tutti gli alberi e normalizzando i valori.

3 Risultati

3.1 Differenze tra gruppi ed effect size

Le features EEG sono state confrontate tra soggetti ADHD e Control mediante test di Mann-Whitney U. Per quantificare la grandezza della differenza tra i gruppi è stato calcolato Cohen's d . Le prime dieci feature ordinate secondo il valore assoluto di Cohen's d sono riportate nella Tabella 3.

Feature	ADHD mean	Control mean	Cohen's d	p_{FDR}
temporal_theta_beta_ratio	1.861	2.746	-0.717	0.030
T7_theta_beta_ratio	2.206	3.402	-0.657	0.039
Pz_theta_beta_ratio	2.449	3.554	-0.638	0.085
P7_theta_beta_ratio	1.364	2.097	-0.596	0.039
P7_theta_power	2262.8	4606.1	-0.585	0.039
P7_delta_power	9224.3	27307.8	-0.562	0.030
Pz_delta_power	11517.6	26783.3	-0.539	0.030
parietal_delta_power_mean	12388.7	25533.5	-0.534	0.191
O1_theta_beta_ratio	1.673	2.329	-0.505	0.227
occipital_theta_beta_ratio	1.477	1.980	-0.484	0.233

Tabella 3: Prime dieci feature EEG ordinate secondo il valore assoluto di Cohen's d . Valori negativi indicano valori medi più alti nel gruppo Control rispetto al gruppo ADHD.

Le feature con maggiore effect size sono prevalentemente associate al rapporto theta/beta e alle potenze nelle bande lente, soprattutto in regioni temporali, parietali e occipitali. Tutte le prime dieci feature mostrano Cohen's d negativo, indicando valori medi più elevati nel gruppo Control.

Per visualizzare la distribuzione spaziale degli effect size, Cohen's d è stato rappresentato sia a livello regionale sia a livello di singolo canale.




Figura 1: Matrice degli effect size regionali. Ogni cella riporta Cohen's d per una combinazione regione-banda. L'asterisco indica una feature significativa dopo correzione FDR.

Anche matrice regionale mostra effect size prevalentemente negativi, in particolare per la banda delta e per il rapporto theta/beta. Il valore più marcato riguarda il rapporto theta/beta temporale, che risulta anche significativo dopo correzione FDR (contrassegnato con *).




Figura 2: Matrice degli effect size a livello di singolo canale. Ogni cella riporta Cohen's d per una combinazione canale-banda. L'asterisco indica una feature significativa dopo correzione FDR.

La matrice canale-livello evidenzia che le differenze più marcate si concentrano soprattutto nei canali temporali e parietali, in particolare per il rapporto theta/beta e per le potenze delta e theta. La rappresentazione a singolo canale conserva maggiore dettaglio spaziale, mentre la rappresentazione regionale fornisce una sintesi più compatta.

3.2 Feature significative dopo correzione FDR

Per controllare il problema dei confronti multipli, i p-value ottenuti dai test di Mann-Whitney U sono stati corretti mediante procedura Benjamini-Hochberg. Le feature con $p_{FDR} < 0.05$ sono state considerate statisticamente significative dopo correzione. I risultati sono riportati nella Tabella 4 e visualizzati in Figura 3.

Feature	ADHD mean	Control mean	Cohen's d	p_{FDR}
temporal_theta_beta_ratio	1.861	2.746	-0.717	0.030
P7_delta_power	9224.3	27307.8	-0.562	0.030
Pz_delta_power	11517.6	26783.3	-0.539	0.030
T7_theta_beta_ratio	2.206	3.402	-0.657	0.039
P7_theta_beta_ratio	1.364	2.097	-0.596	0.039
P7_theta_power	2262.8	4606.1	-0.585	0.039
F4_beta_power	2417.5	2254.9	0.060	0.039

Tabella 4: Feature EEG risultate significative dopo correzione FDR.

Le feature significative dopo correzione FDR confermano il coinvolgimento del rapporto theta/beta e delle bande lente in canali temporali e parietali. La maggior parte di queste feature presenta Cohen's d negativo, quindi valori medi più elevati nel gruppo Control. L'unica feature significativa con effect size positivo è **F4_beta_power**; tuttavia, il valore di Cohen's d è molto piccolo.

FDR significant EEG features




Figura 3: Distribuzione delle feature EEG significative dopo correzione FDR.

3.3 Correlazione tra feature

Per valutare la ridondanza tra feature EEG, sono state calcolate correlazioni di Spearman separatamente nei gruppi ADHD e Control. L'analisi è stata condotta sia sulle feature

canale-livello sia sulle feature regionali.

3.3.1 Correlazioni canale-livello

Le correlazioni più forti tra feature canale-livello sono riportate nella Tabella 5. Sono state selezionate le dieci correlazioni più forti in valore assoluto per ciascun gruppo.

Gruppo	Feature 1	Feature 2	ρ
ADHD	F3_alpha_power	Fz_alpha_power	0.938
ADHD	F3_beta_power	Fz_beta_power	0.917
ADHD	P3_theta_beta_ratio	Pz_theta_beta_ratio	0.912
ADHD	P3_beta_power	Pz_beta_power	0.907
ADHD	P3_theta_power	Pz_theta_power	0.905
ADHD	F3_theta_power	Fz_theta_power	0.885
ADHD	P4_beta_power	Cz_beta_power	0.881
ADHD	O2_delta_power	O2_theta_power	0.876
ADHD	P8_delta_power	P8_theta_power	0.874
ADHD	F4_beta_power	C4_beta_power	0.871
Control	F3_theta_power	C3_theta_power	0.940
Control	F3_alpha_power	Fz_alpha_power	0.937
Control	F3_theta_power	Fz_theta_power	0.930
Control	F4_delta_power	Cz_delta_power	0.926
Control	O1_delta_power	P7_delta_power	0.919
Control	F3_beta_power	Fz_beta_power	0.918
Control	C3_delta_power	Pz_delta_power	0.909
Control	C4_theta_power	Cz_theta_power	0.909
Control	C3_theta_power	P3_theta_power	0.906
Control	P3_delta_power	Pz_delta_power	0.905

Tabella 5: Dieci correlazioni di Spearman più forti in valore assoluto tra feature canale-livello, calcolate separatamente nei gruppi ADHD e Control.

Le correlazioni canale-livello più forti in valore assoluto risultano tutte positive in entrambi i gruppi. Questo indica che le principali ridondanze tra feature derivano soprattutto da potenze della stessa banda o da feature spettrali simili misurate in canali vicini. Nel gruppo ADHD compaiono correlazioni elevate tra canali frontali e parietali, come F3–Fz e P3–Pz. Nel gruppo Control si osservano correlazioni molto alte tra canali frontali, centrali e parietali, in particolare per le bande theta, alpha, beta e delta. Questa struttura conferma che molte feature canale-livello non sono indipendenti, ma descrivono pattern spettrali parzialmente sovrapposti.

3.3.2 Correlazioni regionali

Le matrici di correlazione tra feature regionali sono mostrate in Figura 4. Le dieci correlazioni regionali più forti in valore assoluto sono riportate nella Tabella 6.

Regional EEG feature correlations by group




Figura 4: Matrici di correlazione di Spearman tra feature regionali, calcolate separatamente nei gruppi ADHD e Control.

Gruppo	Feature 1	Feature 2	ρ
ADHD	central_theta_beta_ratio	parietal_theta_beta_ratio	0.834
ADHD	occipital_delta_power_mean	occipital_theta_power_mean	0.830
ADHD	central_beta_power_mean	parietal_beta_power_mean	0.830
ADHD	parietal_delta_power_mean	occipital_delta_power_mean	0.825
ADHD	parietal_alpha_power_mean	temporal_alpha_power_mean	0.788
ADHD	central_delta_power_mean	parietal_delta_power_mean	0.779
ADHD	parietal_theta_power_mean	occipital_theta_power_mean	0.772
ADHD	parietal_delta_power_mean	parietal_theta_power_mean	0.766
ADHD	frontal_alpha_power_mean	temporal_alpha_power_mean	0.757
ADHD	frontal_beta_power_mean	central_beta_power_mean	0.749
Control	parietal_delta_power_mean	occipital_delta_power_mean	0.919
Control	frontal_alpha_power_mean	parietal_alpha_power_mean	0.881
Control	central_delta_power_mean	parietal_delta_power_mean	0.878
Control	central_delta_power_mean	occipital_delta_power_mean	0.863
Control	parietal_theta_power_mean	temporal_theta_power_mean	0.861
Control	parietal_alpha_power_mean	temporal_alpha_power_mean	0.856
Control	occipital_delta_power_mean	occipital_theta_power_mean	0.851
Control	frontal_beta_power_mean	parietal_beta_power_mean	0.845
Control	central_delta_power_mean	temporal_delta_power_mean	0.841
Control	central_alpha_power_mean	parietal_alpha_power_mean	0.839

Tabella 6: Dieci correlazioni di Spearman più forti in valore assoluto tra feature regionali, calcolate separatamente nei gruppi ADHD e Control.

Le correlazioni regionali più forti sono positive in entrambi i gruppi. Nel gruppo ADHD la correlazione più elevata riguarda il rapporto theta/beta centrale e parietale, mentre nel gruppo Control la correlazione maggiore riguarda la potenza delta parietale e occipitale.

3.3.3 Distribuzione delle correlazioni

Le distribuzioni dei coefficienti di Spearman sono riportate separatamente per feature regionali e canale-livello nelle Figure 5 e 6.




Figura 5: Distribuzione delle correlazioni di Spearman tra feature regionali, separatamente per ADHD e Control.




Figura 6: Distribuzione delle correlazioni di Spearman tra feature canale-livello, separatamente per ADHD e Control.

Le distribuzioni mostrano che la maggior parte delle correlazioni è positiva in entrambi i gruppi. Per le feature regionali, il gruppo Control presenta una distribuzione leggermente più spostata verso correlazioni positive elevate, suggerendo una maggiore co-variazione tra feature regionali. Per le feature canale-livello, le distribuzioni dei due gruppi sono più sovrapposte, anche se il gruppo Control mantiene una coda più estesa verso valori positivi alti.

3.4 Classificazione Random Forest

Per valutare il contenuto predittivo delle feature EEG, è stato addestrato un classificatore Random Forest. Sono stati confrontati tre set di feature: tutte le feature EEG, le sole feature canale-livello e le sole feature regionali. Il confronto è stato eseguito mediante cross-validation stratificata a 5 fold sul training/validation set.

Feature set	N	Accuracy	Balanced acc.	Precision	Recall	F1	ROC-AUC
All	120	0.676	0.677	0.660	0.751	0.699	0.674
Channel-level	95	0.614	0.610	0.604	0.707	0.646	0.681
Regional mean	25	0.676	0.678	0.670	0.749	0.700	0.729

Tabella 7: Confronto delle performance medie in cross-validation per i tre insiemi di feature testati con Random Forest.




Figura 7: Confronto delle metriche di cross-validation del modello Random Forest per i tre insiemi di feature.

Le feature regionali ottengono la migliore balanced accuracy media. Le differenze rispetto all'insieme completo non sono ampie, ma il risultato suggerisce che una rappresentazione regionale sia sufficiente a conservare informazione discriminativa, riducendo così la dimensionalità rispetto alle feature relative ai canali singoli.

3.5 Performance del modello finale

Il modello finale, dopo tuning sugli iperparametri ha mostrato performance migliori con parametri:

Iperparametro	Valori ottimali
n_estimators	1028
max_depth	15
min_samples_leaf	2
min_samples_split	2
max_features	log2

Tabella 8: Iperparametri ottimali Random Forest su features regionali.

È stato addestrato sull'intero training/validation set utilizzando le feature regionali, ed è stato valutato sul test set indipendente. Le metriche finali sono riportate nella Tabella 9.

Metrica	Valore
Feature set	Regional mean features
N feature	25
Accuracy	0.760
Balanced accuracy	0.756
Precision	0.733
Recall	0.846
F1-score	0.786
ROC-AUC	0.731

Tabella 9: Metriche finali del modello Random Forest valutato sul test set indipendente.




Figura 8: Confusion matrix del modello Random Forest finale valutato sul test set indipendente.

La confusion matrix mostra 8 soggetti Control correttamente classificati su 12 e 11 soggetti ADHD correttamente classificati su 13. Gli errori sono costituiti da 4 falsi positivi e 2 falsi negativi. Il modello presenta quindi un recall elevato per la classe ADHD, ma una specificità più limitata per la classe Control.

La capacità discriminativa del modello finale è stata valutata anche tramite curva ROC.




Figura 9: Curva ROC del modello Random Forest finale sul test set indipendente. La linea tratteggiata rappresenta la performance casuale.

La curva ROC mostra una capacità di separazione superiore al caso casuale. Il valore di ROC-AUC ottenuto sul test set è pari a 0.72 come già indicato in 9.

3.6 Feature importance

La feature importance della Random Forest è stata utilizzata per identificare le variabili maggiormente coinvolte nella classificazione. Le dieci feature più importanti sono riportate in Figura 10.




Figura 10: Prime dieci feature più importanti secondo il modello Random Forest finale.

La feature più importante è il rapporto theta/beta temporale, coerentemente con l'analisi statistica, in cui la stessa feature presentava il maggiore effect size assoluto. Tra le altre feature rilevanti compaiono potenze di banda centrali, parietali e occipitali.

Per valutare la ridondanza tra le feature maggiormente utilizzate dal modello, è stata calcolata la matrice di correlazione di Spearman tra le dieci feature con maggiore feature importance.




Figura 11: Matrice di correlazione di Spearman tra le dieci feature più importanti secondo la Random Forest.

La matrice mostra che diverse feature importanti sono tra loro correlate. Questo indica che il modello non utilizza dieci feature completamente indipendenti, ma un insieme di variabili parzialmente ridondanti che descrivono aspetti correlati dell'attività spettrale regionale.

3.7 Riduzione del feature set in base alla correlazione

La matrice di correlazione tra le dieci feature più importanti ha mostrato la presenza di correlazioni moderate o elevate tra alcune variabili. Per questo motivo è stata effettuata un'analisi aggiuntiva per valutare se fosse possibile ridurre la ridondanza del feature set senza peggiorare le performance di classificazione.

Le feature sono state ordinate in base alla feature importance ottenuta dal modello Random Forest finale. Successivamente partendo dalla feature più importante, una nuova feature veniva mantenuta solo se la sua correlazione assoluta di Spearman con tutte le feature già selezionate era inferiore a una soglia prefissata. In questo modo, tra feature altamente correlate, veniva conservata quella con maggiore importanza nel modello.

Sono state testate diverse soglie di correlazione sul solo training/validation set mediante cross-validation stratificata a 5 fold.

Soglia	N	Accuracy	Balanced acc.	Precision	Recall	F1	ROC-AUC
0.70	12	0.645	0.647	0.640	0.711	0.664	0.737
0.75	17	0.665	0.668	0.657	0.749	0.693	0.723
0.80	19	0.718	0.719	0.700	0.853	0.750	0.752
0.85	24	0.655	0.658	0.643	0.731	0.674	0.701

Tabella 10: Confronto in cross-validation delle soglie di correlazione utilizzate per ridurre il feature set. Le metriche sono calcolate sul training/validation set.

La soglia selezionata è stata pari a 0.80, poiché ha ottenuto la migliore balanced accuracy media in cross-validation. Il feature set ridotto risultante contiene 19 feature. Dopo la selezione della soglia, il modello Random Forest è stato nuovamente ottimizzato sul feature set ridotto mediante la stessa procedura di tuning utilizzata per il modello principale.

Iperparametro	Valore ottimale
n_estimators	954
max_depth	5
min_samples_leaf	1
min_samples_split	13
max_features	sqrt

Tabella 11: Iperparametri ottimali del modello Random Forest applicato al feature set ridotto in base alla correlazione.

Il modello finale basato sul feature set ridotto è stato addestrato sull'intero training/validation set e valutato sul test set indipendente. Le performance ottenute sono riportate nella Tabella 12.

Metrica	Valore
Soglia di correlazione	0.80
N feature	19
Accuracy	0.720
Balanced accuracy	0.718
Precision	0.714
Recall	0.769
F1-score	0.741
ROC-AUC	0.756

Tabella 12: Metriche finali del modello Random Forest con feature set ridotto, valutato sul test set indipendente.




Figura 12: Confusion matrix del modello Random Forest basato sul feature set ridotto in base alla correlazione.




Figura 13: Curva ROC del modello Random Forest basato sul feature set ridotto in base alla correlazione.

Il confronto con il modello basato sul feature set originale permette di valutare se la rimozione delle feature ridondanti riduca, mantenga o migliori la capacità discriminativa del classificatore. Se le performance rimangono simili, il risultato suggerisce che parte

dell'informazione contenuta nelle feature originali era ridondante; se invece peggiorano, significa che le feature rimosse contribuivano comunque alla classificazione.

3.8 Studio feature theta/beta ratio

L'analisi delle feature importance e degli effect size ha mostrato che alcune feature basate sul rapporto theta/beta sono tra le variabili più rilevanti del dataset, in particolare il rapporto theta/beta temporale. Questo risultato è coerente con la letteratura precedente, che ha spesso associato l'ADHD ad alterazioni del rapporto theta/beta. Tuttavia, alla luce della meta-analisi di Arns et al., è importante distinguere tra la presenza di informazione discriminativa nel TBR e la sua sufficienza come marker diagnostico autonomo [2].

Per questo motivo, è stata condotta un'analisi specifica utilizzando esclusivamente feature derivate dal rapporto theta/beta. Sono stati confrontati tre insiemi di feature: rapporti theta/beta regionali, rapporti theta/beta a livello di singolo canale e l'insieme completo di tutte le feature theta/beta ratio. L'obiettivo era verificare se l'informazione contenuta nel TBR fosse sufficiente per classificare ADHD e controlli, oppure se il modello multifeature mantenesse un vantaggio predittivo.

Il confronto iniziale è stato effettuato mediante cross-validation stratificata a 5 fold sul training/validation set.

Feature set	N	Accuracy	Balanced acc.	Precision	Recall	F1	ROC-AUC
Regional TBR	12	0.542	0.541	0.550	0.644	0.573	0.681
Channel-level TBR	19	0.575	0.576	0.586	0.649	0.609	0.614
All TBR	24	0.553	0.554	0.568	0.649	0.596	0.618

Tabella 13: Confronto in cross-validation dei tre insiemi di feature basati esclusivamente sul rapporto theta/beta.

Il miglior insieme di feature theta/beta ratio è risultato essere **Channel-level TBR**. Questo insieme è stato quindi utilizzato per addestrare un modello Random Forest, ottimizzato con la stessa procedura adottata per i modelli precedenti.

Iperparametro	Valore ottimale
n_estimators	330
max_depth	1
min_samples_leaf	3
min_samples_split	7
max_features	sqrt

Tabella 14: Iperparametri ottimali del modello Random Forest basato sulle sole feature theta/beta ratio.

Le metriche finali sul test set indipendente sono riportate nella Tabella 15.

Metrica	Valore
Accuracy	0.760
Balanced accuracy	0.753
Precision	0.706
Recall	0.923
F1-score	0.800
ROC-AUC	0.705

Tabella 15: Metriche finali del modello Random Forest basato sulle sole feature theta/beta ratio, valutato sul test set indipendente.




Figura 14: Confusion matrix del modello Random Forest basato sulle sole feature theta/beta ratio.




Figura 15: Curva ROC del modello Random Forest basato sulle sole feature theta/beta ratio.

Questa analisi permette di confrontare direttamente l'informazione contenuta nel rapporto theta/beta con quella contenuta nel modello multifeature. Se il modello basato solo su feature theta/beta ottiene performance inferiori rispetto al modello completo o al modello ridotto, ciò suggerisce che il rapporto theta/beta contiene informazione discriminativa ma non è sufficiente, da solo, per una classificazione robusta. Se invece le performance risultano simili, il risultato suggerisce che una parte rilevante dell'informazione discriminativa è catturata proprio dalle feature theta/beta ratio.

Riferimenti bibliografici

- [1] Ali Motie Nasrabadi. Eeg dataset for adhd. DOI:10.21227/rzfh-zn36, 2025.
- [2] Martijn Arns, C. Keith Conners, and Helena C. Kraemer. A decade of eeg theta/beta ratio research in adhd: A meta-analysis. *Journal of Attention Disorders*, 17(5):374–383, 2013.
- [3] Shi-Yi Chen. A general introduction to adjustment for multiple comparisons. 2018.
- [4] Francis Sahngun Nahm. Nonparametric statistical tests for the continuous data: the basic concept and the practical use. 2016.
- [5] Peter D. Welch. The use of fast fourier transform for the estimation of power spectra: A method based on time averaging over short, modified periodograms. 1967.