

Classificazione ADHD vs Control tramite features spettrali e di functional connectivity estratte da EEG

Noemi Aime

1 luglio 2026

Indice

1	Introduzione	2
2	Metodi	2
2.1	Dataset	2
2.2	Estrazione features spettrali	3
2.3	Esplorazione featurea spettrali	4
2.3.1	Test di Mann-Whitney U	4
2.3.2	Cohen's d	4
2.3.3	Correzione per confronti multipli	5
2.3.4	Analisi di correlazione	5
2.4	Classificazione	6
2.4.1	Random Forest	6
2.4.2	Logistic Regression	7
2.5	Features di functional connectivity	8
3	Risultati	9
3.1	Features spettrali	9
3.1.1	Differenze tra gruppi ed effect size	9
3.1.2	Feature significative dopo correzione FDR	11
3.1.3	Correlazione tra feature	13
3.1.4	Correlazioni canale-livello	13
3.1.5	Correlazioni regionali	13
3.1.6	Distribuzione delle correlazioni	14
3.1.7	Classificazione Random Forest	15
3.1.8	Performance del modello finale	16
3.1.9	Feature importance	18
3.1.10	Riduzione del feature set in base alla correlazione	20
3.1.11	Studio feature theta/beta ratio	23
3.1.12	Classificazione con Logistic Regression	25
3.2	Feature di functional connectivity	26
3.2.1	Feature importance delle connessioni funzionali	28
3.2.2	Classificazione con Logistic Regression	29
4	Conclusioni	31

1 Introduzione

Il disturbo da deficit di attenzione e iperattività (ADHD) è un disturbo del neurosviluppo caratterizzato da sintomi di disattenzione, impulsività e iperattività. Questo può influire sul comportamento durante compiti che richiedono concentrazione e risposta a stimoli esterni.

L'elettroencefalografia (EEG) risulta uno strumento utile per studiare l'attività cerebrale associata a questi processi, permette infatti di registrare l'attività elettrica cerebrale con elevata risoluzione temporale. I segnali EEG sono costituiti da serie temporali misurate da elettrodi posizionati sullo scalpo secondo configurazioni standard, come il sistema internazionale 10–20. Attraverso l'analisi di tali segnali è possibile estrarre informazioni sull'attività cerebrale in diverse bande di frequenza, come delta, theta, alpha e beta.

Un indice molto studiato è il rapporto theta/beta, o theta/beta ratio (TBR). Il TBR è stato proposto come possibile misura quantitativa per distinguere soggetti con ADHD da soggetti di controllo. Tuttavia, il suo ruolo diagnostico è ancora discusso. Lo studio di Arns, Conners e Kraemer ([3]) ha mostrato che, sebbene molti studi abbiano riportato un TBR aumentato nei soggetti con ADHD, gli effect size complessivi presentavano una significativa eterogeneità. Inoltre si evidenzia una riduzione della differenza di TBR tra ADHD e controlli nel corso degli anni, principalmente associata a un aumento del TBR nei gruppi di controll.

Per questo motivo, Arns et al. concludono che un TBR elevato non può essere considerato una misura diagnostica affidabile per l'ADHD. A partire da questa osservazione, il presente lavoro non assume il theta/beta ratio come unico marker diagnostico, ma lo analizza all'interno di una pipeline multifeature. Recentemente, l'analisi della functional connectivity EEG è stata proposta come rappresentazione complementare alle tradizionali feature spettrali per la classificazione dell'ADHD. In particolare, Ahmadi Moghadam et al. hanno proposto un approccio basato su mappe di connettività EEG ottenute combinando Pearson Correlation Coefficient e Phase-Locking Value, successivamente utilizzate come input per un modello deep learning ([1]). Nel presente lavoro non viene replicata tale architettura, ma viene adottata una strategia più semplice, basata su feature di connettività derivate dalla correlazione di Pearson e valutate mediante modelli Random Forest e Logistic Regression.

L'obiettivo del progetto è valutare se differenti rappresentazioni dei segnali EEG possano distinguere soggetti ADHD e Control.

2 Metodi

2.1 Dataset

Il dataset utilizzato è disponibile su Kaggle ([2]). Contiene registrazioni EEG di 61 bambini con ADHD e 60 soggetti di controllo, di età compresa tra 7 e 12 anni, registrati durante un compito di attenzione visiva in cui si mostra ai bambini immagini di personaggi di cartoni animati. La distribuzione delle classi risulta approssimativamente bilanciata.

Le registrazioni sono state acquisite con frequenza di campionamento $f_s = 128$ Hz.

Il dataset contiene 19 canali EEG:

Fp1, Fp2, F3, F4, C3, C4, P3, P4, O1, O2, F7, F8, T7, T8, P7, P8, Fz, Cz, Pz.

I canali seguono la nomenclatura del sistema internazionale 10-20, in cui la distanza tra gli elettrodi che viene calcolata in percentuali (10% o 20%) rispetto alla lunghezza

della testa, misurata in senso fronto-occipitale e laterale. Le lettere dei canali indicano approssimativamente la regione corticale sottostante: **Fp** indica la regione frontopolare, **F** la regione frontale, **C** la regione centrale, **P** la regione parietale, **O** la regione occipitale e **T** la regione temporale. I numeri dispari indicano elettrodi localizzati prevalentemente sull'emisfero sinistro, mentre i numeri pari indicano elettrodi localizzati prevalentemente sull'emisfero destro. Gli elettrodi indicati con la lettera **z**, come **Fz**, **Cz** e **Pz**, si trovano lungo la linea mediana.

Durante la registrazione non sono presenti variazioni di condizione associate al target e al task.

2.2 Estrazione features spettrali

L'estrazione delle feature è stata effettuata a partire dalle serie temporali EEG di ciascun soggetto. Per ogni soggetto e per ogni canale EEG, il segnale temporale è stato trasformato nel dominio della frequenza mediante stima della Power Spectral Density.

La Power Spectral Density, o PSD, descrive come la potenza del segnale è distribuita sulle diverse frequenze. La PSD è stata stimata utilizzando il metodo di Welch. Tale metodo suddivide il segnale in finestre temporali parzialmente sovrapposte, calcola lo spettro per ciascuna finestra e infine media gli spettri ottenuti.

I parametri utilizzati per il metodo di Welch sono stati:

$$n_{\text{perseg}} = 512, \quad n_{\text{overlap}} = 256$$

Poiché la frequenza di campionamento è pari a 128 Hz, una finestra di 512 campioni corrisponde a $\frac{512}{128} = 4$ s

La risoluzione in frequenza della PSD è quindi $\Delta f = \frac{f_s}{n_{\text{perseg}}} = \frac{128}{512} = 0.25$ Hz.

A partire dalla PSD sono state calcolate le potenze nelle principali bande EEG: delta, theta, alpha e beta. Gli intervalli di frequenza utilizzati sono riportati nella Tabella 1.

Banda EEG	Intervallo di frequenza
Delta (δ)	1–4 Hz
Theta (θ)	4–8 Hz
Alpha (α)	8–12 Hz
Beta (β)	12–30 Hz

Tabella 1: Bande di frequenza utilizzate per il calcolo delle feature spettrali.

La potenza di ciascuna banda è stata calcolata integrando la PSD nell'intervallo di frequenze corrispondente (f_1, f_2):

$$P_{\text{band}} = \int_{f_1}^{f_2} PSD(f), df \quad (1)$$

In aggiunta alle potenze di banda, è stato calcolato il rapporto tra theta e beta, definito come:

$$TBR = \frac{P_{\theta}}{P_{\beta}} \quad (2)$$

Ogni feature è stata calcolata sia a livello di singolo canale sia a livello regionale mediando le features dei canali appartenenti alla stessa regione.

L'output finale della features extraction è una tabella soggetto-livello contenente potenze di banda per ciascun canale, rapporti theta/beta per ciascun canale, potenze medie regionali, rapporti theta/beta regionali e metadati del soggetto, come identificativo, classe e durata della registrazione.

2.3 Esplorazione featurea spettrali

Dopo l'estrazione delle feature, è stata eseguita un'analisi esplorativa per studiare la distribuzione delle variabili e confrontare i due gruppi ADHD e Control.

2.3.1 Test di Mann-Whitney U

Per confrontare ciascuna feature tra soggetti ADHD e soggetti Control è stato utilizzato il test di Mann-Whitney U.

Questo è un test non parametrico per il confronto tra due gruppi indipendenti. È stato scelto perché le feature EEG possono non seguire una distribuzione normale. A differenza del test t di Student, il test di Mann-Whitney non confronta direttamente le medie dei due gruppi, ma confronta i ranghi dei valori.

Il procedimento consiste nel considerare insieme tutti i valori della feature nei due gruppi, ordinarli dal più piccolo al più grande e assegnare a ciascun valore un rango. Se i due gruppi provengono dalla stessa distribuzione, i ranghi dovrebbero essere distribuiti in modo simile tra ADHD e Control. Se invece un gruppo tende ad avere valori più alti o più bassi, anche i ranghi tenderanno a essere sistematicamente più alti o più bassi.

Per un gruppo con n_1 osservazioni, la statistica U_1 può essere scritta come:

$$U_1 = R_1 - \frac{n_1(n_1 + 1)}{2} \quad (3)$$

dove R_1 è la somma dei ranghi del primo gruppo.

La statistica U finale del test viene calcolata come il valore minimo tra U_1 e la controparte U_2 del secondo gruppo.

Nel presente progetto è stato utilizzato un test a due code, poiché non si è imposto a priori che le feature dovessero essere maggiori nel gruppo ADHD o nel gruppo Control. In questo modo, il test è sensibile a differenze in entrambe le direzioni.

Il p-value misura quanto la differenza osservata tra ADHD e Control sia compatibile con l'ipotesi che i due gruppi non differiscano realmente. Se il p-value è piccolo, la differenza osservata è poco compatibile con questa ipotesi e può essere considerata statisticamente significativa. Se invece il p-value è grande, la differenza potrebbe essere dovuta alla variabilità casuale dei dati.

2.3.2 Cohen's d

Oltre alla significatività statistica, è stata calcolata una misura della grandezza dell'effetto tramite Cohen's d .

Il p-value indica se una differenza è statisticamente significativa, ma non descrive direttamente quanto tale differenza sia grande. Per questo motivo, Cohen's d è stato utilizzato per quantificare la differenza standardizzata tra le medie dei due gruppi.

Cohen's d è definito come:

$$d = \frac{\mu_{ADHD} - \mu_{Control}}{s_{pooled}} \quad (4)$$

dove μ_{ADHD} è la media della feature nel gruppo ADHD, $\mu_{Control}$ è la media della feature nel gruppo Control e s_{pooled} è la deviazione standard pooled.

La deviazione standard pooled si definisce come:

$$s_{pooled} = \sqrt{\frac{s_{ADHD}^2 + s_{Control}^2}{2}} \quad (5)$$

dove s_{ADHD} e $s_{Control}$ sono le deviazioni standard nei due gruppi.

Il valore assoluto di Cohen's d è stato utilizzato per ordinare le feature in base alla grandezza della differenza tra i gruppi.

In questo modo è stato possibile identificare le feature con la maggiore separazione tra ADHD e Control, indipendentemente dalla direzione della differenza.

2.3.3 Correzione per confronti multipli

Poiché il confronto statistico è stato ripetuto su molte feature EEG, è stato necessario correggere i p-value per confronti multipli ([4]).

Eseguendo diversi test statistici aumenta la probabilità di ottenere risultati apparentemente significativi solo per caso. Per ridurre questo rischio è stata utilizzata la procedura Benjamini-Hochberg per il controllo del False Discovery Rate.

Il False Discovery Rate controlla la proporzione attesa di falsi positivi tra le feature dichiarate significative.

La procedura Benjamini-Hochberg ordina i p-value dal più piccolo al più grande:

$$p_{(1)} \leq p_{(2)} \leq \dots \leq p_{(m)} \quad (6)$$

dove m è il numero totale di test eseguiti.

Ogni p-value ordinato viene confrontato con una soglia che dipende dalla sua posizione $\frac{i}{m}Q$ dove i è il rango del p-value ordinato, m è il numero totale di test e Q è il livello di False Discovery Rate scelto.

Nel progetto sono state considerate significative dopo correzione le feature con:

$$p_{FDR} < 0.05$$

2.3.4 Analisi di correlazione

Dopo il confronto tra gruppi, è stata analizzata la correlazione tra tutte le feature EEG numeriche.

Molte feature EEG possono essere correlate tra loro perché derivano dalla stessa banda di frequenza, da canali spazialmente vicini o da rapporti calcolati a partire dalle stesse grandezze.

È stata utilizzata la correlazione di Spearman, una misura non parametrica di associazione monotona tra due variabili. A differenza della correlazione di Pearson, Spearman non richiede che la relazione tra le variabili sia lineare e non richiede l'assunzione di normalità.

Il coefficiente di Spearman si basa sui ranghi delle osservazioni. Date due variabili X e Y , i valori vengono trasformati nei rispettivi ranghi $R(X)$ e $R(Y)$, e la correlazione viene calcolata sui ranghi.

Nel caso senza ranghi uguali, il coefficiente di Spearman può essere scritto come:

$$\rho = 1 - \frac{6 \sum_{i=1}^n d_i^2}{n(n^2 - 1)} \quad (7)$$

dove d_i è la differenza tra i ranghi delle due variabili per l'osservazione i , e n è il numero di osservazioni.

Il coefficiente ρ varia tra -1 e 1 e $\rho = 1$ indica una relazione monotona positiva perfetta e $\rho = -1$ indica una relazione monotona negativa perfetta, mentre $\rho = 0$ indica assenza di relazione monotona.

2.4 Classificazione

Dopo l'estrazione e l'analisi esplorativa delle feature EEG, si sono classificati i re soggetti ADHD e soggetti Control. Ogni soggetto è stato rappresentato mediante un vettore di feature, ottenuto a partire dalle registrazioni EEG. La classe diagnostica, ADHD oppure Control, è stata utilizzata come variabile target.

Sono stati considerati due modelli di classificazione: Random Forest e Logistic Regression. La Random Forest è stata utilizzata come modello non lineare, capace di catturare relazioni complesse tra le feature EEG. La Logistic Regression è stata invece utilizzata come modello lineare di confronto, con l'obiettivo di verificare se la separazione tra i due gruppi potesse essere ottenuta anche tramite una combinazione lineare delle feature.

Prima dell'addestramento, il dataset soggetto-livello è stato diviso in due sottoinsiemi:

- training/validation set, pari all'80% dei soggetti;
- test set indipendente, pari al 20% dei soggetti.

La divisione è stata effettuata in modo da mantenere proporzioni simili di soggetti ADHD e Control nei due sottoinsiemi. Il test set è stato mantenuto separato durante la fase di selezione del modello e di ottimizzazione degli iperparametri, ed è stato utilizzato solo per la valutazione finale.

Sul training/validation set è stata eseguita una cross-validation stratificata a 5 fold. In ogni iterazione, il modello è stato addestrato su quattro fold e validato sul fold rimanente. La procedura è stata ripetuta cinque volte, in modo che ogni fold fosse utilizzato una volta come validation set.

Le metriche utilizzate per valutare le prestazioni dei modelli sono state: accuracy, balanced accuracy, precision, recall, F1-score, ROC-AUC e confusion matrix.

2.4.1 Random Forest

La Random Forest è un modello di classificazione ensemble basato sulla combinazione di molti alberi decisionali. Ogni albero viene addestrato su una diversa sottoinsieme del training set e, durante la costruzione dei nodi, considera solo un sottoinsieme casuale delle feature disponibili. Questa doppia casualità riduce la dipendenza del modello da un singolo albero e migliora la capacità di generalizzazione.

Nel caso della classificazione, ogni albero della Random Forest produce una predizione di classe. La predizione finale corrisponde a quella di maggioranza. Nell'implementazione di `scikit-learn`, la Random Forest stima inoltre la probabilità di appartenenza a ciascuna classe mediando le probabilità prodotte dai singoli alberi, e assegna il campione alla classe con probabilità media più alta.

Nel presente lavoro, la Random Forest è stata utilizzata sia per valutare le performance di classificazione sia per stimare l'importanza relativa delle feature. È stato inoltre utilizzato il parametro `class_weight="balanced"` per compensare eventuali differenze nella distribuzione delle classi.

Tuning degli iperparametri: Il tuning degli iperparametri è stato eseguito sul miglior feature set selezionato nella fase precedente, utilizzando esclusivamente il training/validation set.

L'ottimizzazione degli iperparametri è stata effettuata in due passaggi. È stata inizialmente utilizzata una `RandomizedSearchCV` per esplorare in modo efficiente uno spazio ampio di possibili combinazioni di iperparametri. Successivamente, è stata applicata una `GridSearchCV` locale attorno alla migliore combinazione individuata dalla ricerca randomizzata, con l'obiettivo di raffinare ulteriormente la selezione degli iperparametri.

Entrambe le fasi di tuning sono state eseguite mediante cross-validation stratificata a 5 fold sul training/validation set. La metrica utilizzata per selezionare la migliore combinazione di iperparametri è stata la balanced accuracy.

Dopo la selezione finale degli iperparametri, il modello Random Forest è stato riaddestrato sull'intero training/validation set e valutato una sola volta sul test set.

Feature importance: Dopo l'addestramento del modello finale, sono stati estratti i valori di feature importance della Random Forest.

La feature importance della Random Forest si basa sulla riduzione media dell'impurità, chiamata anche mean decrease in impurity. In un albero decisionale, ogni nodo viene diviso scegliendo la feature e la soglia che permettono di separare meglio le classi.

Come misura comune dell'impurità si usa la Gini impurity:

$$Gini = 1 - p_{ADHD}^2 - p_{Control}^2 \quad (8)$$

dove p_k è la proporzione di campioni appartenenti alla classe k nel nodo.

La riduzione di impurità prodotta da uno split è calcolata come:

$$\Delta I = I_{parent} \left(\frac{N_{left}}{N_{parent}} I_{left} + \frac{N_{right}}{N_{parent}} I_{right} \right) \quad (9)$$

Una feature viene considerata importante se viene utilizzata in split che riducono fortemente l'impurità. Nella Random Forest, l'importanza viene calcolata mediando il contributo della feature su tutti gli alberi e normalizzando i valori.

2.4.2 Logistic Regression

La Logistic Regression è un classificatore che stima la probabilità di appartenenza a una classe a partire da una combinazione lineare delle feature. Nel caso binario, il modello calcola una probabilità associata alla classe positiva (ADHD).

Data una combinazione lineare delle feature,

$$z = w_0 + w_1x_1 + w_2x_2 + \dots + w_px_p, \quad (10)$$

la Logistic Regression applica una funzione sigmoide per trasformare il valore z in una probabilità compresa tra 0 e 1:

$$P(y = 1|x) = \frac{1}{1 + e^{-z}}. \quad (11)$$

I coefficienti w_j indicano il contributo delle singole feature alla classificazione. Coefficienti positivi aumentano la probabilità stimata della classe ADHD, mentre coefficienti negativi la riducono, favorendo la classe Control..

La Logistic Regression è sensibile alla scala delle variabili, la standardizzazione delle feature è stata inclusa mediante `StandardScaler`, in cui la media e la deviazione standard utilizzate per la normalizzazione vengono calcolate esclusivamente sul training set in ciascun fold di cross-validation.

Tuning degli iperparametri: L'iperparametro principale ottimizzato è stato il parametro di regolarizzazione $C = \lambda^{-1}$, che controlla l'intensità della penalizzazione applicata ai coefficienti del modello. Valori piccoli di C corrispondono a una penalizzazione più forte, mentre valori grandi di C riducono l'effetto della regolarizzazione. La penalizzazione utilizzata è stata L_2 , utilizzata per ridurre il rischio di overfitting.

$$L_2 = \lambda \sum_{j=1}^p w_j^2 \quad (12)$$

dove w_j rappresenta il coefficiente associato alla feature j , p è il numero totale di feature e λ controlla l'intensità della penalizzazione.

Il tuning è stato eseguito mediante `GridSearchCV` con cross-validation stratificata a 5 fold sul training/validation set.

2.5 Features di functional connectivity

Per ogni soggetto, i segnali EEG sono stati filtrati separatamente nelle bande delta, theta, alpha e beta. Successivamente, per ciascuna banda, è stata calcolata la correlazione di Pearson tra tutte le coppie di canali EEG. Ogni valore di correlazione è stato utilizzato come feature di connettività canale-livello.

In aggiunta, sono state calcolate feature di connettività media regionale.

Sono stati così confrontati tre insiemi di feature di connettività:

1. tutte le feature di functional connectivity;
2. solo le feature di connettività tra canali;
3. solo le feature di connettività tra regioni.

Dato un segnale EEG $x(t)$ e un secondo segnale $y(t)$, il coefficiente di Pearson è definito come:

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}} \quad (13)$$

Il coefficiente assume valori compresi tra -1 e 1 . Valori positivi indicano che i due segnali tendono a variare nella stessa direzione, valori negativi indicano un andamento opposto, mentre valori prossimi a zero indicano assenza di correlazione lineare.

La classificazione è stata effettuata utilizzando sia Random Forest sia Logistic Regression. Questa è stata eseguita con le stesse modalità descritte per le feature spettrali.

3 Risultati

3.1 Features spettrali

3.1.1 Differenze tra gruppi ed effect size

Si riportano le matrici di effect size per Cohen's d , rappresentate separatamente a livello regionale e a livello di singolo canale. L'asterisco indica una feature significativa dopo correzione FDR.




Figura 1: Matrice degli effect size regionali. Ogni cella riporta Cohen's d per una combinazione regione-banda. L'asterisco indica una feature significativa dopo correzione FDR.




Figura 2: Matrice degli effect size a livello di singolo canale. Ogni cella riporta Cohen's d per una combinazione canale-banda. L'asterisco indica una feature significativa dopo correzione FDR.

Le feature con maggiore effect size sono prevalentemente associate al rapporto theta/beta e alle potenze nelle bande lente, soprattutto in regioni temporali, parietali e occipitali. Inoltre, la maggior parte di queste mostrano Cohen's d negativo, indicando valori medi più elevati nel gruppo Control.

Per riassumere si mostrano le prime dieci feature ordinate secondo il valore assoluto di Cohen's d nella Tabella 2.

Feature	ADHD mean	Control mean	Cohen's d	p_{FDR}
temporal_theta_beta_ratio	1.861	2.746	-0.717	0.030
T7_theta_beta_ratio	2.206	3.402	-0.657	0.039
Pz_theta_beta_ratio	2.449	3.554	-0.638	0.085
P7_theta_beta_ratio	1.364	2.097	-0.596	0.039
P7_theta_power	2262.8	4606.1	-0.585	0.039
P7_delta_power	9224.3	27307.8	-0.562	0.030
Pz_delta_power	11517.6	26783.3	-0.539	0.030
parietal_delta_power_mean	12388.7	25533.5	-0.534	0.191
O1_theta_beta_ratio	1.673	2.329	-0.505	0.227
occipital_theta_beta_ratio	1.477	1.980	-0.484	0.233

Tabella 2: Prime dieci feature EEG ordinate secondo il valore assoluto di Cohen's d .

3.1.2 Feature significative dopo correzione FDR

Le feature con $p_{FDR} < 0.05$ sono state considerate statisticamente significative dopo correzione. I risultati sono riportati nella Tabella 3 e visualizzati in Figura 3.

Feature	ADHD mean	Control mean	Cohen's d	p_{FDR}
temporal_theta_beta_ratio	1.861	2.746	-0.717	0.030
P7_delta_power	9224.3	27307.8	-0.562	0.030
Pz_delta_power	11517.6	26783.3	-0.539	0.030
T7_theta_beta_ratio	2.206	3.402	-0.657	0.039
P7_theta_beta_ratio	1.364	2.097	-0.596	0.039
P7_theta_power	2262.8	4606.1	-0.585	0.039
F4_beta_power	2417.5	2254.9	0.060	0.039

Tabella 3: Feature EEG risultate significative dopo correzione FDR.

Le feature significative dopo correzione FDR confermano il coinvolgimento del rapporto theta/beta e delle bande lente in canali temporali e parietali. La maggior parte di queste feature presenta Cohen's d negativo, quindi valori medi più elevati nel gruppo Control. L'unica feature significativa con effect size positivo è **F4_beta_power**; tuttavia, il valore di Cohen's d è molto piccolo.

FDR significant EEG features




Figura 3: Distribuzione delle feature EEG significative dopo correzione FDR.

3.1.3 Correlazione tra feature

3.1.4 Correlazioni canale-livello

Le correlazioni più forti tra feature canale-livello sono riportate nella Tabella 4. Sono state selezionate le dieci correlazioni più forti in valore assoluto per ciascun gruppo.

Gruppo	Feature 1	Feature 2	ρ
ADHD	F3_alpha_power	Fz_alpha_power	0.938
ADHD	F3_beta_power	Fz_beta_power	0.917
ADHD	P3_theta_beta_ratio	Pz_theta_beta_ratio	0.912
ADHD	P3_beta_power	Pz_beta_power	0.907
ADHD	P3_theta_power	Pz_theta_power	0.905
ADHD	F3_theta_power	Fz_theta_power	0.885
ADHD	P4_beta_power	Cz_beta_power	0.881
ADHD	O2_delta_power	O2_theta_power	0.876
ADHD	P8_delta_power	P8_theta_power	0.874
ADHD	F4_beta_power	C4_beta_power	0.871
Control	F3_theta_power	C3_theta_power	0.940
Control	F3_alpha_power	Fz_alpha_power	0.937
Control	F3_theta_power	Fz_theta_power	0.930
Control	F4_delta_power	Cz_delta_power	0.926
Control	O1_delta_power	P7_delta_power	0.919
Control	F3_beta_power	Fz_beta_power	0.918
Control	C3_delta_power	Pz_delta_power	0.909
Control	C4_theta_power	Cz_theta_power	0.909
Control	C3_theta_power	P3_theta_power	0.906
Control	P3_delta_power	Pz_delta_power	0.905

Tabella 4: Dieci correlazioni di Spearman più forti in valore assoluto tra feature canale-livello, calcolate separatamente nei gruppi ADHD e Control.

Le correlazioni canale-livello più forti in valore assoluto risultano tutte positive in entrambi i gruppi. Questo indica che le principali ridondanze tra feature derivano soprattutto da potenze della stessa banda o da feature spettrali simili misurate in canali vicini. Nel gruppo ADHD compaiono correlazioni elevate tra canali frontali e parietali, come F3–Fz e P3–Pz. Nel gruppo Control si osservano correlazioni molto alte anche tra canali centrali. Questa struttura conferma che molte feature canale-livello non sono indipendenti, ma descrivono pattern spettrali parzialmente sovrapposti.

3.1.5 Correlazioni regionali

Le correlazioni più forti tra feature regionali sono riportate nella Tabella

Gruppo	Feature 1	Feature 2	ρ
ADHD	central_theta_beta_ratio	parietal_theta_beta_ratio	0.834
ADHD	occipital_delta_power_mean	occipital_theta_power_mean	0.830
ADHD	central_beta_power_mean	parietal_beta_power_mean	0.830
ADHD	parietal_delta_power_mean	occipital_delta_power_mean	0.825
ADHD	parietal_alpha_power_mean	temporal_alpha_power_mean	0.788
ADHD	central_delta_power_mean	parietal_delta_power_mean	0.779
ADHD	parietal_theta_power_mean	occipital_theta_power_mean	0.772
ADHD	parietal_delta_power_mean	parietal_theta_power_mean	0.766
ADHD	frontal_alpha_power_mean	temporal_alpha_power_mean	0.757
ADHD	frontal_beta_power_mean	central_beta_power_mean	0.749
Control	parietal_delta_power_mean	occipital_delta_power_mean	0.919
Control	frontal_alpha_power_mean	parietal_alpha_power_mean	0.881
Control	central_delta_power_mean	parietal_delta_power_mean	0.878
Control	central_delta_power_mean	occipital_delta_power_mean	0.863
Control	parietal_theta_power_mean	temporal_theta_power_mean	0.861
Control	parietal_alpha_power_mean	temporal_alpha_power_mean	0.856
Control	occipital_delta_power_mean	occipital_theta_power_mean	0.851
Control	frontal_beta_power_mean	parietal_beta_power_mean	0.845
Control	central_delta_power_mean	temporal_delta_power_mean	0.841
Control	central_alpha_power_mean	parietal_alpha_power_mean	0.839

Tabella 5: Dieci correlazioni di Spearman più forti in valore assoluto tra feature regionali, calcolate separatamente nei gruppi ADHD e Control.

Le correlazioni regionali più forti sono positive in entrambi i gruppi. Nel gruppo ADHD la correlazione più elevata riguarda il rapporto theta/beta centrale e parietale, mentre nel gruppo Control la correlazione maggiore riguarda la potenza delta parietale e occipitale.

3.1.6 Distribuzione delle correlazioni

Le distribuzioni dei coefficienti di Spearman sono riportate separatamente per feature regionali e canale-livello nelle Figure 4 e 5.




Figura 4: Distribuzione delle correlazioni di Spearman tra feature regionali, separatamente per ADHD e Control.




Figura 5: Distribuzione delle correlazioni di Spearman tra feature canale-livello, separatamente per ADHD e Control.

Le distribuzioni mostrano che la maggior parte delle correlazioni è positiva in entrambi i gruppi. Per le feature regionali, il gruppo Control presenta una distribuzione leggermente più spostata verso correlazioni positive elevate, suggerendo una maggiore co-variazione tra feature regionali. Per le feature canale-livello, le distribuzioni dei due gruppi sono più sovrapposte, anche se il gruppo Control mantiene una coda più estesa verso valori positivi alti.

3.1.7 Classificazione Random Forest

Per valutare il contenuto predittivo delle feature EEG, è stato addestrato un classificatore Random Forest. Sono stati confrontati tre set di feature: tutte le feature EEG, le sole feature canale-livello e le sole feature regionali. Il confronto è stato eseguito mediante cross-validation stratificata a 5 fold sul training/validation set.

Feature set	N	Accuracy	Balanced acc.	Precision	Recall	F1	ROC-AUC
All	120	0.676	0.677	0.660	0.751	0.699	0.674
Channel-level	95	0.614	0.610	0.604	0.707	0.646	0.681
Regional mean	25	0.676	0.678	0.670	0.749	0.700	0.729

Tabella 6: Confronto delle performance medie in cross-validation per i tre insiemi di feature testati con Random Forest.




Figura 6: Confronto delle metriche di cross-validation del modello Random Forest per i tre insiemi di feature.

Le feature regionali ottengono la migliore balanced accuracy media. Le differenze rispetto all'insieme completo non sono ampie, ma il risultato suggerisce che una rappresentazione regionale sia sufficiente a conservare informazione discriminativa, riducendo così la dimensionalità rispetto alle feature relative ai canali singoli.

3.1.8 Performance del modello finale

Il modello finale, dopo tuning sugli iperparametri ha mostrato performance migliori con parametri:

Iperparametro	Valori ottimali
n_estimators	1028
max_depth	15
min_samples_leaf	2
min_samples_split	2
max_features	log2

Tabella 7: Iperparametri ottimali Random Forest su features regionali.

È stato addestrato sull'intero training/validation set utilizzando le feature regionali, ed è stato valutato sul test set indipendente. Le metriche finali sono riportate nella Tabella 8.

Metrica	Valore
Feature set	Regional mean features
N feature	25
Accuracy	0.760
Balanced accuracy	0.756
Precision	0.733
Recall	0.846
F1-score	0.786
ROC-AUC	0.731

Tabella 8: Metriche finali del modello Random Forest valutato sul test set indipendente.




Figura 7: Confusion matrix del modello Random Forest finale valutato sul test set indipendente.

La confusion matrix mostra 8 soggetti Control correttamente classificati su 12 e 11 soggetti ADHD correttamente classificati su 13. Gli errori sono costituiti da 4 falsi positivi e 2 falsi negativi. Il modello presenta quindi un recall elevato per la classe ADHD, ma una specificità più limitata per la classe Control.

La capacità discriminativa del modello finale è stata valutata anche tramite curva ROC.




Figura 8: Curva ROC del modello Random Forest finale sul test set indipendente. La linea tratteggiata rappresenta la performance casuale.

La curva ROC mostra una capacità di separazione superiore al caso casuale. Il valore di ROC-AUC ottenuto sul test set è pari a 0.72 come già indicato in 8.

3.1.9 Feature importance

La feature importance della Random Forest è stata utilizzata per identificare le variabili maggiormente coinvolte nella classificazione. Le dieci feature più importanti sono riportate in Figura 9.




Figura 9: Prime dieci feature più importanti secondo il modello Random Forest finale.

La feature più importante è il rapporto theta/beta temporale, coerentemente con l'analisi statistica, in cui la stessa feature presentava il maggiore effect size assoluto. Tra le altre feature rilevanti compaiono potenze di banda centrali, parietali e occipitali.

Per valutare la ridondanza tra le feature maggiormente utilizzate dal modello, è stata calcolata la matrice di correlazione di Spearman tra le dieci feature con maggiore feature importance.




Figura 10: Matrice di correlazione di Spearman tra le dieci feature più importanti secondo la Random Forest.

La matrice mostra che diverse feature importanti sono tra loro correlate. Questo indica che il modello non utilizza dieci feature completamente indipendenti, ma un insieme di variabili parzialmente ridondanti che descrivono aspetti correlati dell'attività spettrale regionale.

3.1.10 Riduzione del feature set in base alla correlazione

È stata effettuata un'analisi aggiuntiva per valutare se fosse possibile ridurre la ridondanza del feature set senza peggiorare le performance di classificazione.

Le feature sono state ordinate in base alla feature importance ottenuta dal modello Random Forest finale. Successivamente partendo dalla feature più importante, una nuova feature veniva mantenuta solo se la sua correlazione assoluta di Spearman con tutte le feature già selezionate era inferiore a una soglia prefissata. In questo modo, tra feature altamente correlate, veniva conservata quella con maggiore importanza nel modello.

Sono state testate diverse soglie di correlazione sul solo training/validation set mediante cross-validation stratificata a 5 fold.

Soglia	N	Accuracy	Balanced acc.	Precision	Recall	F1	ROC-AUC
0.70	12	0.645	0.647	0.640	0.711	0.664	0.737
0.75	17	0.665	0.668	0.657	0.749	0.693	0.723
0.80	19	0.718	0.719	0.700	0.853	0.750	0.752
0.85	24	0.655	0.658	0.643	0.731	0.674	0.701

Tabella 9: Confronto in cross-validation delle soglie di correlazione utilizzate per ridurre il feature set. Le metriche sono calcolate sul training/validation set.

La soglia selezionata è stata pari a 0.80. Il feature set ridotto risultante contiene 19 feature. Dopo la selezione della soglia, il modello Random Forest è stato nuovamente ottimizzato sul feature set ridotto mediante la stessa procedura di tuning utilizzata per il modello principale.

Iperparametro	Valore ottimale
n_estimators	954
max_depth	5
min_samples_leaf	1
min_samples_split	13
max_features	sqrt

Tabella 10: Iperparametri ottimali del modello Random Forest applicato al feature set ridotto in base alla correlazione.

Il modello finale basato sul feature set ridotto è stato addestrato sull'intero training/validation set e valutato sul test set indipendente. Le performance ottenute sono riportate nella Tabella 11.

Metrica	Valore
Soglia di correlazione	0.80
N feature	19
Accuracy	0.720
Balanced accuracy	0.718
Precision	0.714
Recall	0.769
F1-score	0.741
ROC-AUC	0.756

Tabella 11: Metriche finali del modello Random Forest con feature set ridotto, valutato sul test set indipendente.




Figura 11: Confusion matrix del modello Random Forest basato sul feature set ridotto in base alla correlazione.




Figura 12: Curva ROC del modello Random Forest basato sul feature set ridotto in base alla correlazione.

La riduzione del feature set ha permesso di diminuire il numero di variabili da 25 a 19 mantenendo prestazioni comparabili a quelle del modello basato su tutte le feature regionali. La balanced accuracy risulta leggermente inferiore rispetto al modello regiona-

le completo, mentre la ROC-AUC è lievemente superiore. Questo suggerisce che parte dell'informazione contenuta nelle feature regionali sia ridondante.

3.1.11 Studio feature theta/beta ratio

Alla luce dell'analisi di Arns et al., è interessante distinguere tra la presenza di informazione discriminativa nel TBR e la sua sufficienza come marker diagnostico autonomo [3].

Per questo motivo, è stata condotta un'analisi specifica utilizzando esclusivamente feature derivate dal rapporto theta/beta. Sono stati confrontati tre insiemi di feature: rapporti theta/beta regionali, rapporti theta/beta a livello di singolo canale e l'insieme completo di tutte le feature theta/beta ratio. I metodi utilizzati corrispondono ai precedenti.

Feature set	N	Accuracy	Balanced acc.	Precision	Recall	F1	ROC-AUC
Regional TBR	12	0.542	0.541	0.550	0.644	0.573	0.681
Channel-level TBR	19	0.575	0.576	0.586	0.649	0.609	0.614
All TBR	24	0.553	0.554	0.568	0.649	0.596	0.618

Tabella 12: Confronto in cross-validation dei tre insiemi di feature basati esclusivamente sul rapporto theta/beta.

Il miglior insieme di feature theta/beta ratio è risultato essere Channel-level TBR. Questo insieme è stato quindi utilizzato per addestrare un modello Random Forest, ottimizzato con la stessa procedura adottata per i modelli precedenti.

Iperparametro	Valore ottimale
n_estimators	330
max_depth	1
min_samples_leaf	3
min_samples_split	7
max_features	sqrt

Tabella 13: Iperparametri ottimali del modello Random Forest basato sulle sole feature theta/beta ratio.

Le metriche finali sul test set indipendente sono riportate nella Tabella 14.

Metrica	Valore
Accuracy	0.760
Balanced accuracy	0.753
Precision	0.706
Recall	0.923
F1-score	0.800
ROC-AUC	0.705

Tabella 14: Metriche finali del modello Random Forest basato sulle sole feature theta/beta ratio, valutato sul test set indipendente.




Figura 13: Confusion matrix del modello Random Forest basato sulle sole feature theta/beta ratio.




Figura 14: Curva ROC del modello Random Forest basato sulle sole feature theta/beta ratio.

Il modello basato sulle sole feature theta/beta ratio ha ottenuto prestazioni simili al modello Random Forest basato sulle feature regionali complete in termini di accuracy e balanced accuracy, ma con una ROC-AUC inferiore. Questo indica che il rapporto theta/beta contiene informazione discriminativa rilevante, ma non descrive completamente la

separazione tra ADHD e Control. Il risultato supporta quindi l'idea che il TBR sia utile all'interno di una pipeline multifeature, ma non sufficiente come unico marker diagnostico.

3.1.12 Classificazione con Logistic Regression

Il feature set regionale, il feature set ridotto in base alla correlazione e il feature set basato esclusivamente sul rapporto theta/beta sono stati valutati mediante Logistic Regression.

In tutti e tre i casi, il valore ottimale del parametro di regolarizzazione è risultato pari a $C = 0.1$.

I risultati finali sul test set indipendente sono riportati nella Tabella 15.

Feature set	N	Accuracy	Balanced acc.	Precision	Recall	F1	ROC-AUC
Regional	25	0.600	0.596	0.600	0.692	0.643	0.615
Correlation-reduced	19	0.560	0.558	0.571	0.615	0.593	0.590
Theta/beta ratio	19	0.720	0.715	0.688	0.846	0.759	0.712

Tabella 15: Performance della Logistic Regression sui diversi insiemi di feature spettrali, valutate sul test set indipendente.

Tra i tre insiemi di feature, il modello basato esclusivamente sul rapporto theta/beta ha ottenuto le prestazioni migliori. Di tale feature set si riporta la confusion matrix e la curva ROC.




Figura 15: Confusion matrix della Logistic Regression basata sulle feature theta/beta ratio, valutata sul test set indipendente.




Figura 16: Curva ROC della Logistic Regression basata sulle feature theta/beta ratio. La linea tratteggiata rappresenta la performance casuale.

Nel complesso, la Logistic Regression ha mostrato prestazioni inferiori rispetto alla Random Forest sulle feature spettrali regionali e ridotte. Tuttavia, il risultato ottenuto con le sole feature theta/beta ratio indica che queste feature sono informative anche per un modello lineare.

3.2 Feature di functional connectivity

Le feature di functional connectivity sono state valutate per verificare se le relazioni temporali tra canali e regioni EEG contenessero informazione utile per distinguere soggetti ADHD e Control. Sono stati confrontati tre insiemi di feature: tutte le feature di connettività, le sole feature di connettività canale-livello e le sole feature di connettività regionale.

Il confronto in cross-validation mediante Random Forest è riportato nella Tabella 16.

Feature set	N	Accuracy	Balanced acc.	Precision	Recall	F1	ROC-AUC
All	724	0.688	0.684	0.661	0.769	0.703	0.721
Channel-level	684	0.709	0.706	0.692	0.791	0.731	0.722
Regional	40	0.710	0.708	0.686	0.773	0.718	0.769

Tabella 16: Confronto in cross-validation dei tre insiemi di feature di functional connectivity mediante Random Forest.

Il miglior feature set di functional connectivity è risultato essere quello basato sulle feature regionali. Questo risultato suggerisce che una rappresentazione regionale della connettività sia sufficiente a conservare informazione discriminativa, riducendo notevolmente la dimensionalità rispetto alle feature di connettività canale-livello.

Il modello Random Forest basato sulle feature regionali è stato quindi ottimizzato mediante la stessa procedura di tuning utilizzata per le feature spettrali. I migliori iperparametri ottenuti sono riportati nella Tabella 17.

Iperparametro	Valore ottimale
n_estimators	330
max_depth	15
min_samples_leaf	3
min_samples_split	10
max_features	log2

Tabella 17: Iperparametri ottimali del modello Random Forest basato sulle feature regionali di functional connectivity.

Il modello finale è stato addestrato sull'intero training/validation set e valutato sul test set indipendente. Le metriche finali sono riportate nella Tabella 18.

Metrica	Valore
Feature set	Regional connectivity features
N feature	40
Accuracy	0.920
Balanced accuracy	0.920
Precision	0.923
Recall	0.923
F1-score	0.923
ROC-AUC	0.929

Tabella 18: Metriche finali del modello Random Forest basato su feature regionali di functional connectivity, valutato sul test set indipendente.




Figura 17: Confusion matrix del modello Random Forest basato su feature regionali di functional connectivity.




Figura 18: Curva ROC del modello Random Forest basato su feature regionali di functional connectivity. La linea tratteggiata rappresenta la performance casuale.

Il modello Random Forest basato sulle feature regionali di functional connectivity ha ottenuto prestazioni superiori rispetto ai modelli basati sulle feature spettrali. Questo risultato suggerisce che le relazioni funzionali tra regioni EEG forniscano una rappresentazione particolarmente informativa per distinguere soggetti ADHD e Control nel dataset analizzato.

3.2.1 Feature importance delle connessioni funzionali

Per interpretare il modello Random Forest basato sulle feature di functional connectivity, è stata analizzata la feature importance delle connessioni regionali. Questa analisi permette di identificare quali coppie di regioni e bande di frequenza contribuiscano maggiormente alla classificazione tra ADHD e Control.




Figura 19: Prime quindici feature di functional connectivity più importanti secondo il modello Random Forest.

Le feature più importanti coinvolgono soprattutto connessioni tra regioni centrali, parietali, temporali e occipitali, in particolare nelle bande beta e alpha. Questo suggerisce che la classificazione non dipenda da una singola connessione, ma da un pattern distribuito di relazioni funzionali tra regioni EEG.

3.2.2 Classificazione con Logistic Regression

Successivamente, lo stesso feature set di connettività regionale è stato valutato mediante Logistic Regression, in modo da confrontare un modello non lineare con un modello lineare a parità di input.




Figura 20: Confusion matrix della Logistic Regression basata su feature regionali di functional connectivity.




Figura 21: Curva ROC della Logistic Regression basata su feature regionali di functional connectivity.

La Logistic Regression basata sulle feature regionali di functional connectivity ha ottenuto prestazioni comparabili, e in parte superiori, a quelle ottenute dalla Random Forest sulle stesse feature. Questo suggerisce che le feature di connettività regionale separino i due gruppi in modo relativamente lineare, almeno nel dataset considerato.

4 Conclusioni




Figura 22: Confronto complessivo delle metriche di classificazione sul test set indipendente per le diverse rappresentazioni EEG e i diversi modelli.

Il confronto complessivo mostra che le feature di functional connectivity regionale ottengono le prestazioni migliori tra tutte le rappresentazioni EEG considerate. Le feature spettrali e il rapporto theta/beta risultano comunque informative, ma mostrano prestazioni inferiori rispetto alla connettività. Questo suggerisce che, nel dataset analizzato, le relazioni funzionali tra regioni EEG rappresentino una descrizione più efficace per la classificazione ADHD vs Control rispetto alle sole misure di potenza spettrale.

È importante sottolineare alcune limitazioni. Il numero di soggetti è relativamente ridotto e il dataset deriva da una specifica condizione sperimentale.

Sviluppi futuri potrebbero includere il confronto con ulteriori misure di connettività.

Riferimenti bibliografici

- [1] Elham Ahmadi Moghadam, Farhad Abedinzadeh Torghabeh, Seyyed Abed Hosseini, and Mohammad Hossein Moattar. Improved adhd diagnosis using eeg connectivity and deep learning through combining pearson correlation coefficient and phase-locking value. *Neuroinformatics*, 22(4):521–537, 2024.
- [2] Ali Motie Nasrabadi. Eeg dataset for adhd. DOI:10.21227/rzfh-zn36, 2025.
- [3] Martijn Arns, C. Keith Conners, and Helena C. Kraemer. A decade of eeg theta/beta ratio research in adhd: A meta-analysis. *Journal of Attention Disorders*, 17(5):374–383, 2013.
- [4] Shi-Yi Chen. A general introduction to adjustment for multiple comparisons. 2018.

- [5] Francis Sahngun Nahm. Nonparametric statistical tests for the continuous data: the basic concept and the practical use. 2016.
- [6] Peter D. Welch. The use of fast fourier transform for the estimation of power spectra: A method based on time averaging over short, modified periodograms. 1967.