

Classificazione ADHD vs Control tramite features spettrali e di functional connectivity estratte da EEG

Noemi Aime

21 luglio 2026

Indice

1	Introduzione	3
2	Metodi	5
2.1	Dataset	5
2.1.1	Protocollo sperimentale	6
2.1.2	Acquisizione EEG	6
2.1.3	Struttura e limitazioni dei dati	7
2.2	Preprocessing del segnale	7
2.2.1	Uniformazione della durata delle registrazioni	7
2.2.2	Conversione delle unità e assegnazione del montaggio	8
2.2.3	Filtraggio passa-banda	8
2.2.4	Riferimento medio comune	9
2.2.5	Independent Component Analysis	9
2.3	Estrazione delle feature spettrali	12
2.3.1	Stima della Power Spectral Density	12
2.3.2	Calcolo delle potenze di banda	13
2.3.3	Theta/beta ratio	14
2.3.4	Feature regionali	14
2.3.5	Struttura del feature set spettrale	15
2.4	Esplorazione delle feature spettrali	15
2.4.1	Test di Mann–Whitney U	15
2.4.2	Cohen’s d	16
2.4.3	Correzione per confronti multipli	17
2.4.4	Correlazione di Spearman	17
2.5	Classificazione	18
2.5.1	Suddivisione dei dati e cross-validation	18
2.5.2	Metriche di valutazione	19
2.5.3	Random Forest	19
2.5.4	Logistic Regression	21
2.6	Feature di functional connectivity	21
2.6.1	Filtraggio nelle singole bande	22
2.6.2	Correlazione di Pearson	22
2.6.3	Connettività tra canali	22
2.6.4	Connettività regionale	23

3	Risultati	23
3.1	Feature spettrali	23
3.1.1	Effect size delle differenze tra i gruppi	23
3.1.2	Feature significative dopo correzione FDR	26
3.1.3	Ridondanza tra le feature spettrali	26
3.2	Classificazione basata sulle feature spettrali	28
3.2.1	Confronto dei feature set mediante Random Forest	28
3.2.2	Random Forest sul feature set completo	29
3.2.3	Feature importance spettrale	31
3.2.4	Riduzione del feature set mediante correlazione	32
3.2.5	Classificazione mediante il theta/beta ratio	34
3.2.6	Logistic Regression sulle feature spettrali	37
3.3	Feature di functional connectivity	41
3.3.1	Descrizione globale della connettività canale-livello	41
3.3.2	Confronto dei feature set di connettività	43
3.3.3	Random Forest sulla functional connectivity	43
3.3.4	Feature importance delle connessioni	45
3.3.5	Logistic Regression sulla functional connectivity	46
4	Conclusioni	47
4.1	Sintesi dei risultati	48
4.2	Caratterizzazione dei gruppi nel dataset analizzato	49
4.3	Confronto con il lavoro di Ahmadi Moghadam et al.	50
4.4	Criticità e limitazioni	51
4.5	Sviluppi futuri	52
4.6	Conclusione generale	53

1 Introduzione

Il disturbo da deficit di attenzione e iperattività (*Attention-Deficit Hyperactivity Disorder*, ADHD) è un disturbo del neurosviluppo caratterizzato da livelli persistenti di disattenzione, impulsività e iperattività. Poiché i sintomi riguardano anche la capacità di selezionare gli stimoli rilevanti, mantenere l'attenzione e controllare la risposta comportamentale, lo studio dell'attività cerebrale durante compiti attentivi può fornire informazioni utili sui meccanismi neurofisiologici associati al disturbo.

L'elettroencefalografia (EEG) è una tecnica non invasiva che misura le differenze di potenziale elettrico registrate da elettrodi posizionati sullo scalpo. Il segnale rilevato da ciascun elettrodo non corrisponde all'attività di un singolo neurone o di una singola area cerebrale, ma riflette la sovrapposizione dell'attività sincronizzata di popolazioni neuronali e la sua propagazione attraverso i tessuti della testa. Il principale vantaggio dell'EEG è l'elevata risoluzione temporale, che permette di descrivere variazioni dell'attività cerebrale nell'ordine dei millisecondi e lo rende particolarmente adatto allo studio di processi dinamici come l'attenzione.

Le registrazioni EEG multicanale possono essere analizzate attraverso rappresentazioni differenti e complementari. Una prima possibilità consiste nello studiare il contenuto spettrale del segnale, cioè come la sua potenza sia distribuita nelle diverse frequenze. L'attività EEG viene comunemente suddivisa in bande, tra cui delta, theta, alpha e beta. Queste bande non corrispondono in modo univoco a una specifica funzione cognitiva: il loro significato dipende dalla regione considerata, dallo stato del soggetto e dalla condizione sperimentale. Per esempio, un aumento dell'attività theta può essere associato a sonnolenza o riduzione della vigilanza, ma la theta frontale può anche riflettere processi di controllo cognitivo e monitoraggio. Analogamente, l'attività alpha può diminuire nelle aree coinvolte nell'elaborazione visiva oppure aumentare nelle regioni che contribuiscono all'inibizione di informazioni irrilevanti.

Un indice particolarmente studiato nella letteratura sull'ADHD è il *theta/beta ratio* (TBR), definito come il rapporto tra la potenza della banda theta e quella della banda beta:

$$\text{TBR} = \frac{P_{\theta}}{P_{\beta}}. \quad (1)$$

Storicamente, diversi studi condotti su bambini con ADHD avevano riportato un aumento dell'attività theta e, in alcuni casi, una riduzione dell'attività beta. Un TBR elevato era stato quindi interpretato come un maggiore peso dell'attività lenta rispetto a quella più rapida e proposto come possibile indicatore di una regolazione attentiva meno efficiente. Alcuni dei primi lavori riportavano una separazione molto marcata tra soggetti con ADHD e controlli, alimentando l'ipotesi che il TBR potesse essere utilizzato come biomarcatore diagnostico quantitativo.

La validità di questa ipotesi è stata riesaminata da Arns, Conners e Kraemer attraverso una meta-analisi dedicata al TBR [2]. Per rendere gli studi maggiormente confrontabili, gli autori hanno considerato esclusivamente il theta/beta ratio calcolato sul segnale registrato dal canale Cz durante la condizione a occhi aperti, in bambini e adolescenti di età compresa tra 6 e 18 anni. Cz è l'elettrodo situato sulla linea mediana nella regione centrale dello scalpo secondo il sistema internazionale 10–20. La scelta di un'unica posizione e di una stessa condizione di registrazione ha permesso di ridurre la variabilità metodologica tra gli studi. Sono stati inclusi nove studi, per un totale di 1253 soggetti con ADHD e

517 controlli. L'effect size medio, calcolato come Hedges' d , risultava pari a 0.75 nella fascia 6–13 anni e a 0.62 nella fascia 6–18 anni. Tali valori sembrerebbero indicare una differenza moderata o elevata; tuttavia, in entrambe le analisi il test di eterogeneità risultava significativo. Le differenze tra gli studi erano quindi troppo ampie per essere attribuite esclusivamente alla variabilità casuale del campionamento, indicando che il TBR non rappresentava un effetto stabile e uniforme.

L'analisi degli autori ha inoltre evidenziato una progressiva riduzione dell'effect size negli studi più recenti. Questa tendenza non era principalmente determinata da una diminuzione del TBR nel gruppo ADHD, che rimaneva relativamente stabile, ma da un aumento del TBR nei gruppi di controllo. I due gruppi diventavano quindi progressivamente più simili. Tra le possibili spiegazioni vengono discusse differenze nella selezione dei controlli, nelle condizioni di registrazione, negli strumenti e nelle procedure di preprocessing, oltre a fattori fisiologici come sonno, stanchezza e livello di vigilanza.

La conclusione della meta-analisi non è che il TBR sia completamente privo di informazione. Un eccesso di theta o un TBR elevato può caratterizzare soggetti con ADHD e può avere valore prognostico, per esempio nella previsione della risposta a specifici trattamenti. Il suo impiego diagnostico richiederebbe invece una differenza stabile e riproducibile nella maggior parte dei soggetti, condizione che non risulta supportata dall'eterogeneità osservata. Il TBR non può quindi essere considerato, da solo, un marker diagnostico universale dell'ADHD.

Questa distinzione è particolarmente importante per il presente lavoro. Il dataset utilizzato è stato acquisito durante un compito di attenzione visiva, mentre la meta-analisi di Arns et al. considera registrazioni a occhi aperti in condizioni standardizzate e limitatamente all'elettrodo Cz. L'attività theta e beta può essere modulata dal compito e non è quindi possibile assumere a priori che il TBR debba presentare nel dataset analizzato la stessa direzione descritta nei primi studi a riposo. Il TBR viene pertanto valutato sia come insieme di feature autonomo sia all'interno di una rappresentazione spettrale più ampia, comprendente le potenze delle diverse bande e la loro distribuzione sui canali e sulle regioni dello scalpo.

Una rappresentazione complementare del segnale è fornita dalla *functional connectivity*. Mentre le feature spettrali descrivono quanta attività sia presente in una determinata banda e in una determinata posizione, la connettività funzionale descrive il grado di dipendenza statistica tra segnali registrati in posizioni diverse. Essa non dimostra l'esistenza di una connessione anatomica diretta e non consente, di per sé, di stabilire una relazione causale o una direzione dell'interazione. Permette però di rappresentare l'EEG come una rete di relazioni tra elettrodi o regioni, anziché come un insieme di canali indipendenti.

Un riferimento importante per questa seconda linea di analisi è il lavoro di Ahmadi Moghadam et al. [1], particolarmente rilevante perché utilizza lo stesso dataset considerato nel presente progetto. Gli autori analizzano registrazioni EEG di 121 bambini, 61 con ADHD e 60 controlli, acquisite mediante 19 canali a una frequenza di campionamento di 128 Hz durante un compito di attenzione visiva. Dopo il preprocessing, i segnali vengono suddivisi nelle bande delta, theta, alpha, beta e gamma e segmentati in epoche non sovrapposte di sei secondi.

Per ogni banda e per ogni epoca, gli autori costruiscono due matrici di connettività 19×19 . La prima utilizza il *Pearson Correlation Coefficient* (PCC), che misura la covariazione lineare tra le ampiezze di due segnali. La seconda utilizza il *Phase-Locking Value* (PLV), che misura invece la stabilità nel tempo della differenza di fase tra due segnali. Le due misure descrivono quindi aspetti differenti della relazione: due segnali possono mostrare

una debole correlazione delle ampiezze ma mantenere una relazione di fase relativamente stabile.

Poiché sia la matrice di Pearson sia quella di PLV sono simmetriche, i due triangoli di ciascuna matrice conterrebbero informazioni duplicate. Gli autori sfruttano questa proprietà per costruire una *Fused Connectivity Map*: il triangolo inferiore contiene i valori di Pearson, mentre quello superiore contiene i valori di PLV. Si ottiene così una matrice della stessa dimensione di una singola mappa di connettività, ma contenente due forme complementari di informazione.

Le mappe fuse vengono successivamente trattate come immagini e fornite in ingresso a una rete neurale convoluzionale dotata di un meccanismo di *channel attention*. I filtri convoluzionali apprendono configurazioni locali nella matrice di connettività, mentre il modulo di attention assegna un peso maggiore alle feature map considerate più informative per la classificazione. In questo contesto, il termine “channel” nel modulo di attention non indica gli elettrodi EEG, ma le feature map interne prodotte dagli strati convoluzionali. Il modello migliore riportato dagli autori utilizza le mappe della banda theta e raggiunge un’accuracy del 98.88%.

Nel presente progetto non viene replicata integralmente questa architettura. L’obiettivo non è confrontare direttamente un modello tradizionale con la rete neurale proposta nel paper, poiché preprocessing, rappresentazione dei dati, segmentazione e procedura di addestramento sono differenti. Viene invece ripresa la sua motivazione centrale: verificare se le relazioni tra segnali contengano informazione discriminante ulteriore rispetto alle sole potenze spettrali. Per mantenere la pipeline più semplice e interpretabile, la connettività viene stimata mediante correlazione di Pearson e sintetizzata sia a livello di coppie di canali sia a livello di coppie di regioni.

Le feature ottenute vengono quindi valutate mediante Random Forest e Logistic Regression.

L’obiettivo generale del lavoro è dunque confrontare differenti rappresentazioni dello stesso segnale EEG per la classificazione di soggetti con ADHD e soggetti di controllo. Non è individuare a priori un singolo biomarcatore dell’ADHD, ma stabilire quale rappresentazione del segnale conservi l’informazione più utile per distinguere i due gruppi.

2 Metodi

2.1 Dataset

Il dataset utilizzato nel presente lavoro è disponibile pubblicamente su Kaggle [?] e deriva da registrazioni EEG effettuate presso il Psychology and Psychiatry Research Center del Roozbeh Hospital di Teheran.

Il campione comprende complessivamente 121 bambini, di cui 61 con diagnosi di ADHD e 60 soggetti di controllo, con età compresa tra 7 e 12 anni. Per il gruppo di controllo sono stati esclusi soggetti con disturbi psichiatrici ed epilessia. Tutti i partecipanti erano destrimani.

La numerosità dei due gruppi è pressoché equivalente; il problema di classificazione può quindi essere considerato sostanzialmente bilanciato.

2.1.1 Protocollo sperimentale

Le registrazioni sono state effettuate durante un compito di attenzione visiva. Ai bambini venivano mostrate immagini contenenti personaggi e veniva chiesto di contarne il numero. Dopo la risposta del partecipante veniva immediatamente presentata l'immagine successiva.

La durata della registrazione non era prefissata, ma dipendeva dal tempo impiegato da ciascun bambino per completare il compito. Per questo motivo le registrazioni presentano durate differenti tra i soggetti. Nel dataset originale, la durata media riportata è pari a

$$154.59 \pm 58.13 \text{ s} \quad (2)$$

per il gruppo ADHD e a

$$124.91 \pm 29.90 \text{ s} \quad (3)$$

per il gruppo di controllo.

Questa variabilità ha reso necessario, nella successiva fase di preprocessing, selezionare per tutti i soggetti un intervallo temporale della stessa durata.

2.1.2 Acquisizione EEG

I segnali EEG sono stati acquisiti con una frequenza di campionamento pari a

$$f_s = 128 \text{ Hz}, \quad (4)$$

Il sistema comprendeva 19 elettrodi posizionati secondo il sistema internazionale 10–20.

I canali utilizzati nelle analisi sono:

Fp1, Fp2, F3, F4, C3, C4, P3, P4, O1, O2, F7, F8, T7, T8, P7, P8, Fz, Cz, Pz.

Il sistema 10–20 definisce le posizioni degli elettrodi sulla base di distanze pari al 10% o al 20% di alcune misure anatomiche della testa, considerate lungo le direzioni fronto-occipitale e latero-laterale. Questa procedura consente di ottenere un posizionamento riproducibile tra soggetti con dimensioni e forme della testa differenti.

Le lettere presenti nei nomi dei canali indicano la regione dello scalpo in cui l'elettrodo è collocato: **Fp** indica le posizioni frontopolari, **F** quelle frontali, **C** quelle centrali, **T** quelle temporali, **P** quelle parietali e **O** quelle occipitali. Tale nomenclatura fornisce un'indicazione topografica approssimativa e non deve essere interpretata come una localizzazione precisa della sorgente corticale che genera il segnale.

I numeri dispari identificano gli elettrodi situati sul lato sinistro dello scalpo, mentre i numeri pari identificano quelli situati sul lato destro. La lettera **z**, presente nei canali **Fz**, **Cz** e **Pz**, indica invece le posizioni collocate lungo la linea mediana.

Nel dataset originale gli elettrodi laterali erano indicati secondo la precedente nomenclatura del sistema 10–20. Prima dell'analisi i nomi sono stati uniformati alla nomenclatura attuale mediante le seguenti corrispondenze:

$$T3 \rightarrow T7, \quad T4 \rightarrow T8, \quad T5 \rightarrow P7, \quad T6 \rightarrow P8. \quad (5)$$

2.1.3 Struttura e limitazioni dei dati

Il dataset è organizzato in formato tabellare. Ogni riga corrisponde a un campione temporale, mentre le colonne contengono i valori registrati dai 19 canali EEG, l'identificativo del soggetto e la classe diagnostica.

Sebbene l'EEG sia stato acquisito durante un compito costituito da più immagini successive, nel dataset non sono disponibili marcatori temporali dettagliati relativi alla comparsa degli stimoli, alle risposte dei partecipanti o alla correttezza delle singole risposte.

Per questa ragione le analisi sono state invece condotte sul segnale continuo, ricavando per ogni soggetto feature spettrali e di connettività che descrivono complessivamente l'intervallo temporale considerato.

2.2 Preprocessing del segnale

Prima di estrarre le features è necessario eseguire una fase di preprocessing.

La procedura comprendeva:

1. uniformazione della durata delle registrazioni;
2. conversione dei valori da microvolt a volt;
3. assegnazione delle coordinate del montaggio standard 10–20;
4. filtraggio passa-banda tra 1 e 45 Hz;
5. applicazione del riferimento medio comune;
6. decomposizione ICA e classificazione delle componenti.

2.2.1 Uniformazione della durata delle registrazioni

Le registrazioni originali presentavano durate differenti, poiché il tempo necessario per completare il compito dipendeva dalla velocità di risposta del singolo partecipante.

L'utilizzo di segnali di durata diversa avrebbe potuto introdurre una fonte di variabilità metodologica. Per garantire che tutti i soggetti contribuissero alle analisi con la stessa quantità di segnale, è stato quindi selezionato un intervallo temporale massimo comune.

Per ogni soggetto sono stati esclusi i primi 2 secondi della registrazione e sono stati mantenuti i successivi 60 secondi. Il segmento analizzato corrisponde pertanto all'intervallo:

$$t \in [2, 62) \text{ s.} \quad (6)$$

L'esclusione dei primi 2 secondi è stata introdotta per ridurre la possibile influenza della fase iniziale di assestamento della registrazione e dell'avvio del compito. Non essendo disponibili marcatori temporali dettagliati, tale esclusione non corrisponde alla rimozione di uno specifico evento sperimentale, ma rappresenta una scelta metodologica applicata in modo identico a tutti i soggetti.

Con una frequenza di campionamento pari a 128 Hz, ogni registrazione preprocessata contiene quindi:

$$N = 60 \text{ s} \cdot 128 \text{ campioni/s} = 7680 \text{ campioni} \quad (7)$$

per ciascuno dei 19 canali.

2.2.2 Conversione delle unità e assegnazione del montaggio

Nel dataset i valori EEG erano espressi in microvolt. Poiché MNE-Python rappresenta internamente i segnali EEG nelle unità del Sistema Internazionale, i dati sono stati convertiti in volt:

$$x_V(t) = x_{\mu V}(t) \cdot 10^{-6}. \quad (8)$$

Per ciascun soggetto è stato successivamente costruito un oggetto `RawArray` di MNE, organizzato nella forma canali $\times$ campioni.

Ai canali sono state assegnate le coordinate del montaggio `standard_1020`. Le coordinate spaziali sono necessarie sia per rappresentare le topografie EEG sia per fornire a `ICLabel` informazioni sulla distribuzione delle componenti sullo scalpo.

2.2.3 Filtraggio passa-banda

Il segmento EEG selezionato è stato filtrato tra 1 e 45 Hz mediante un filtro FIR (*Finite Impulse Response*) progettato con il metodo `firwin` e applicato a fase zero:

$$1 \text{ Hz} \leq f \leq 45 \text{ Hz}. \quad (9)$$

Un filtro FIR calcola ciascun campione del segnale in uscita come una combinazione lineare di un numero finito di campioni del segnale in ingresso:

$$y[n] = \sum_{k=0}^{L-1} h[k]x[n-k], \quad (10)$$

dove $x[n]$ è il segnale originale, $y[n]$ il segnale filtrato, $h[k]$ sono i coefficienti del filtro e L rappresenta la lunghezza del filtro.

La denominazione *finite impulse response* deriva dal fatto che la risposta del filtro a un impulso ha durata finita.

Il limite inferiore a 1 Hz attenua le derive molto lente della linea di base, che possono derivare da variazioni dell'impedenza degli elettrodi, movimenti lenti e instabilità strumentali. Queste componenti possono presentare ampiezza elevata e influenzare sia la stima della potenza spettrale sia la decomposizione ICA.

Il limite superiore a 45 Hz conserva le bande di frequenza utilizzate nel progetto e attenua le componenti ad alta frequenza, parte dell'attività muscolare e il rumore della rete elettrica localizzato a 50 Hz. Il filtro non elimina necessariamente in modo assoluto tutte le frequenze superiori a 45 Hz, ma ne riduce progressivamente l'ampiezza.

La frequenza di campionamento del segnale è pari a 128 Hz. Secondo il teorema del campionamento, la massima frequenza teoricamente rappresentabile senza ambiguità è la frequenza di Nyquist:

$$f_{\text{Nyquist}} = \frac{f_s}{2} = \frac{128}{2} = 64 \text{ Hz}. \quad (11)$$

Questo limite deriva dal fatto che sono necessari almeno due campioni per rappresentare un ciclo di oscillazione. Componenti con frequenza superiore a 64 Hz non possono essere rappresentate correttamente e possono comparire artificialmente a frequenze inferiori attraverso un fenomeno chiamato *aliasing*.

La frequenza di taglio superiore di 45 Hz è quindi inferiore alla frequenza di Nyquist e lascia un margine per la banda di transizione del filtro.

I coefficienti di un filtro FIR possono essere scelti simmetrici, ottenendo una risposta a fase lineare. In una normale applicazione causale, questa proprietà introduce un ritardo temporale costante, approssimativamente pari a:

$$\tau_g = \frac{L-1}{2} \quad (12)$$

campioni.

Nel presente lavoro il filtro è stato applicato a fase zero, compensando tale ritardo e mantenendo il segnale filtrato temporalmente allineato a quello originale. L'espressione "fase zero" non indica che la fase fisiologica del segnale EEG venga annullata, ma che il filtraggio non introduce uno spostamento di fase netto artificiale.

2.2.4 Riferimento medio comune

Dopo il filtraggio è stato applicato il riferimento medio. L'EEG non misura un potenziale elettrico assoluto, ma una differenza di potenziale rispetto a un riferimento. La scelta del riferimento influenza pertanto sia l'ampiezza dei segnali sia le relazioni osservate tra i canali.

Per ogni istante temporale è stata calcolata la media dei 19 canali:

$$\bar{x}(t) = \frac{1}{M} \sum_{j=1}^M x_j(t), \quad M = 19, \quad (13)$$

e tale media è stata sottratta da ciascun canale:

$$x_i^{\text{CAR}}(t) = x_i(t) - \bar{x}(t). \quad (14)$$

Il riferimento medio non elimina la necessità di un riferimento, ma sostituisce quello originario con una stima distribuita sull'intero insieme degli elettrodi. In questo modo si riduce la dipendenza del segnale da una singola posizione di riferimento e si rende più uniforme il confronto tra i canali.

2.2.5 Independent Component Analysis

Motivazione e principio generale Un elettrodo EEG non registra l'attività di una singola sorgente cerebrale. Il segnale misurato in ogni posizione dello scalpo è una combinazione di diversi contributi, tra cui attività neurale, movimenti oculari, attività muscolare e rumore strumentale.

Una stessa sorgente può inoltre essere rilevata da più elettrodi. Un battito di ciglia, per esempio, produce un segnale particolarmente evidente nei canali frontali, ma il suo effetto può propagarsi anche verso canali più posteriori.

L'Independent Component Analysis (ICA) è una tecnica di *blind source separation* che cerca di separare queste sorgenti a partire dai soli segnali registrati, senza conoscere in anticipo la loro forma.

Il modello ICA assume che i segnali osservati siano combinazioni lineari di sorgenti non direttamente osservabili:

$$\mathbf{X} = \mathbf{A}\mathbf{S}, \quad (15)$$

dove $\mathbf{X}$ contiene i segnali registrati dagli elettrodi, $\mathbf{S}$ contiene le componenti indipendenti e $\mathbf{A}$ è la matrice di mescolamento, che descrive come ogni componente si proietta sui diversi canali.

L'algoritmo stima una matrice di separazione, indicata con $\mathbf{W}$, attraverso la quale ricostruire le componenti:

$$\hat{\mathbf{S}} = \mathbf{W}\mathbf{X}. \quad (16)$$

Indipendenza e non gaussianità L'ICA cerca componenti statisticamente il più possibile indipendenti. L'indipendenza è una condizione più forte della semplice assenza di correlazione: due segnali possono avere correlazione lineare nulla ma presentare comunque una relazione statistica non lineare.

Nel contesto EEG, questo non significa che le sorgenti cerebrali siano realmente indipendenti dal punto di vista fisiologico. L'indipendenza viene utilizzata come criterio matematico per ottenere una rappresentazione nella quale attività neurale e artefatti risultino più separati rispetto ai segnali originali.

L'ICA sfrutta anche la non gaussianità delle sorgenti. In generale, una combinazione di segnali indipendenti tende a essere più simile a una distribuzione gaussiana rispetto ai segnali originari. Cercando componenti con distribuzioni maggiormente non gaussiane, l'algoritmo può quindi risalire alle sorgenti che hanno prodotto le miscele registrate.

Gli artefatti oculari sono spesso adatti a questo tipo di separazione, poiché i battiti di ciglia sono eventi relativamente brevi, di grande ampiezza e con una distribuzione spaziale prevalentemente frontale.

PCA e numero di componenti Prima dell'ICA, MNE centra i dati, applica una procedura di whitening ed esegue una Principal Component Analysis (PCA).

La PCA trasforma i dati in componenti non correlate e ordinate in base alla quantità di varianza spiegata. L'ICA opera successivamente su questo spazio cercando componenti non soltanto non correlate, ma il più possibile indipendenti.

Nel presente lavoro è stato impostato:

$$\text{n_components} = 0.95. \quad (17)$$

Questo valore indica che, per ogni soggetto, viene selezionato il numero minimo di componenti principali necessario a spiegare almeno il 95% della varianza dei dati. Il numero effettivo di componenti può quindi variare leggermente tra i soggetti.

Con 19 canali e riferimento medio comune, il rango massimo teorico dei dati è pari a 18, poiché la somma dei segnali riferiti alla media è nulla a ogni istante.

Il restante contributo PCA non viene necessariamente eliminato dal segnale: durante la ricostruzione finale MNE può reinserire la parte dei dati non utilizzata per stimare l'ICA.

Ottimizzazione mediante Picard La decomposizione ICA è stata ottimizzata mediante Picard (*Preconditioned ICA for Real Data*).

Picard è un algoritmo numerico progettato per raggiungere la soluzione ICA in modo rapido e stabile.

Nel presente lavoro è stata utilizzata la seguente configurazione:

```

method = "picard"
fit_params = {
    "ortho": False,
    "extended": True
}

```

L'opzione `extended=True` abilita una formulazione di tipo Extended Infomax. Questa permette di trattare sia componenti super-gaussiane, caratterizzate da eventi rari e di grande ampiezza, sia componenti sub-gaussiane, caratterizzate da distribuzioni più piatte.

L'opzione `ortho=False` consente a Picard di stimare una matrice di separazione non vincolata all'ortogonalità, ottenendo una configurazione compatibile con Extended Infomax.

Sono stati inoltre impostati:

$$\text{random_state} = 42, \quad \text{max_iter} = 3000. \quad (18)$$

Il primo parametro rende riproducibile l'inizializzazione dell'algoritmo, mentre il secondo definisce il numero massimo di iterazioni consentite. La convergenza è stata verificata controllando che l'algoritmo terminasse prima di raggiungere tale limite.

Classificazione delle componenti L'ICA produce una decomposizione statistica, ma non stabilisce automaticamente quali componenti rappresentino attività cerebrale e quali siano dovute ad artefatti.

Le componenti sono state quindi classificate mediante ICLabel, un modello automatico che utilizza informazioni relative alla topografia, allo spettro di potenza e all'andamento temporale di ciascuna componente.

ICLabel assegna a ogni componente una probabilità di appartenenza a categorie quali:

- attività cerebrale;
- attività muscolare;
- artefatto oculare;
- attività cardiaca;
- rumore di linea;
- rumore di canale;
- altre sorgenti.

Il dataset non contiene canali EOG separati, che avrebbero permesso di identificare direttamente gli artefatti oculari. La classificazione automatica ha quindi utilizzato soprattutto la distribuzione spaziale, le caratteristiche temporali e lo spettro delle componenti.

È stata adottata una procedura conservativa, sono state eliminate soltanto le componenti classificate come oculari con probabilità almeno pari a:

$$p_{\text{eye}} \geq 0.90. \quad (19)$$

Le componenti classificate come muscolari, rumore di linea o altre sorgenti non sono state rimosse automaticamente, per ridurre il rischio di eliminare anche attività cerebrale.

Ricostruzione del segnale Dopo aver identificato le componenti oculari, queste sono state escluse dalla ricostruzione del segnale.

In termini schematici, le componenti selezionate vengono poste a zero e il segnale viene ricostruito utilizzando tutte le componenti rimanenti:

$$\widehat{\mathbf{X}}_{\text{clean}} = \widehat{\mathbf{A}}\widehat{\mathbf{S}}_{\text{clean}}. \quad (20)$$

Non vengono quindi eliminati interi elettrodi o interi intervalli temporali. Da ogni canale viene sottratto soltanto il contributo delle componenti identificate come artefatti oculari.

Limiti dell'ICA L'ICA fornisce una separazione statistica e non una ricostruzione anatomica esatta delle sorgenti cerebrali. Una componente può contenere contributi provenienti da più generatori, mentre una stessa sorgente può essere distribuita tra componenti differenti.

La separazione è inoltre limitata dal numero di elettrodi disponibili. Con 19 canali è possibile ottenere soltanto una rappresentazione a bassa dimensionalità rispetto al numero reale di sorgenti neurali e artefatti.

L'ICA assume anche che la modalità con cui le sorgenti si proiettano sugli elettrodi rimanga approssimativamente costante durante l'intervallo analizzato. Movimenti degli elettrodi o variazioni dell'impedenza possono ridurre la validità di questa ipotesi.

Infine, una componente classificata come artefattuale può contenere anche una parte di attività neurale. Per questo motivo è stata adottata una soglia elevata e una strategia conservativa di esclusione.

2.3 Estrazione delle feature spettrali

L'estrazione delle feature spettrali è stata effettuata a partire dai segnali EEG preelaborati. Per ciascun soggetto e per ciascuno dei 19 canali, la serie temporale di 60 secondi è stata trasformata dal dominio del tempo al dominio della frequenza mediante la stima della densità spettrale di potenza (*Power Spectral Density*, PSD).

La rappresentazione temporale descrive come il potenziale elettrico varia nel tempo, mentre la rappresentazione spettrale descrive come la potenza del segnale è distribuita tra le diverse frequenze. Questo passaggio è particolarmente utile per l'EEG, poiché numerosi fenomeni neurofisiologici vengono descritti in termini di attività oscillatoria all'interno di specifiche bande di frequenza.

2.3.1 Stima della Power Spectral Density

Per un segnale discreto $x[n]$, campionato alla frequenza f_s , la trasformata discreta di Fourier permette di rappresentare il segnale come combinazione di componenti sinusoidali:

$$X[k] = \sum_{n=0}^{N-1} x[n]e^{-j2\pi kn/N}. \quad (21)$$

Il modulo quadrato della trasformata fornisce una misura della potenza associata alle diverse frequenze. Una stima basata direttamente sull'intero segnale, detta periodogramma, presenta tuttavia una varianza elevata: piccole variazioni del segnale possono produrre oscillazioni considerevoli nella stima dello spettro.

Per ottenere una PSD più stabile è stato utilizzato il metodo di Welch. Il segnale viene suddiviso in K segmenti temporali parzialmente sovrapposti. Per ciascun segmento viene calcolato un periodogramma e le stime ottenute vengono successivamente mediate:

$$\hat{S}_{xx}(f) = \frac{1}{K} \sum_{k=1}^K P_k(f), \quad (22)$$

dove $P_k(f)$ è il periodogramma del segmento k .

La media dei periodogrammi riduce la varianza della stima rispetto all'utilizzo di un unico segmento. Il vantaggio viene ottenuto al prezzo di una minore risoluzione temporale, che non costituisce però un limite rilevante nel presente lavoro, poiché l'obiettivo è ottenere una rappresentazione spettrale complessiva del soggetto e non seguire l'evoluzione temporale delle bande durante il compito.

Sono stati utilizzati i seguenti parametri:

$$n_{\text{perseg}} = 512, \quad n_{\text{overlap}} = 256. \quad (23)$$

Poiché la frequenza di campionamento è pari a 128 Hz, ogni segmento contiene quattro secondi di segnale:

$$T_{\text{window}} = \frac{n_{\text{perseg}}}{f_s} = \frac{512}{128} = 4 \text{ s}. \quad (24)$$

L'overlap è pari al 50%, poiché due finestre consecutive condividono 256 dei 512 campioni. La sovrapposizione permette di aumentare il numero di periodogrammi disponibili per la media senza ridurre ulteriormente la lunghezza delle finestre.

La distanza tra due frequenze consecutive della PSD è:

$$\Delta f = \frac{f_s}{n_{\text{perseg}}} = \frac{128}{512} = 0.25 \text{ Hz}. \quad (25)$$

Una finestra di quattro secondi rappresenta quindi un compromesso tra la necessità di distinguere le frequenze delle bande considerate e la necessità di disporre di un numero sufficiente di segmenti da mediare.

2.3.2 Calcolo delle potenze di banda

A partire dalla PSD sono state calcolate le potenze assolute nelle bande delta, theta, alpha e beta. Gli intervalli utilizzati nell'estrazione delle feature spettrali sono riportati nella Tabella 1.

Banda EEG	Intervallo di frequenza
Delta (δ)	1–4 Hz
Theta (θ)	4–8 Hz
Alpha (α)	8–13 Hz
Beta (β)	13–30 Hz

Tabella 1: Bande utilizzate per l'estrazione delle feature spettrali.

La potenza in una banda compresa tra f_1 e f_2 è definita come l'area della PSD nell'intervallo corrispondente:

$$P_{\text{band}} = \int_{f_1}^{f_2} \hat{S}_{xx}(f) df. \quad (26)$$

Poiché la PSD è disponibile soltanto in corrispondenza di frequenze discrete, l'integrale è stato approssimato numericamente mediante la regola del trapezio:

$$P_{\text{band}} \approx \sum_m \frac{S(f_m) + S(f_{m+1})}{2} (f_{m+1} - f_m). \quad (27)$$

Nel codice sono state incluse le frequenze che soddisfano:

$$f \geq f_{\min}, \quad f < f_{\max}. \quad (28)$$

Le potenze ottenute sono potenze assolute.

2.3.3 Theta/beta ratio

Per ciascun canale è stato inoltre calcolato il rapporto tra la potenza theta e la potenza beta:

$$\text{TBR} = \frac{P_{\theta}}{P_{\beta}}. \quad (29)$$

Il rapporto è stato impostato come valore mancante nel caso, puramente teorico, in cui la potenza beta fosse pari a zero. Nei dati analizzati non sono stati osservati valori mancanti nelle feature finali.

2.3.4 Feature regionali

Oltre alle feature dei singoli canali, sono state costruite feature regionali aggregando gli elettrodi nelle seguenti cinque regioni:

- frontale: Fp1, Fp2, F3, F4, F7, F8, Fz;
- centrale: C3, C4, Cz;
- temporale: T7, T8;
- parietale: P3, P4, P7, P8, Pz;
- occipitale: O1, O2.

Per ciascuna regione e banda, la potenza regionale è stata ottenuta mediando le potenze dei canali appartenenti alla regione:

$$P_{R,b} = \frac{1}{|R|} \sum_{c \in R} P_{c,b}, \quad (30)$$

dove R indica la regione, $|R|$ il numero di canali appartenenti alla regione e b la banda di frequenza.

Il theta/beta ratio regionale è stato calcolato come rapporto tra la potenza theta media della regione e la potenza beta media della stessa regione:

$$\text{TBR}_R = \frac{P_{R,\theta}}{P_{R,\beta}}. \quad (31)$$

Non è stata quindi calcolata la media dei TBR dei singoli canali; prima sono state mediate separatamente le potenze theta e beta e successivamente ne è stato calcolato il rapporto.

2.3.5 Struttura del feature set spettrale

Per ciascuno dei 19 canali sono state ottenute quattro potenze di banda e un theta/beta ratio:

$$19 \times (4 + 1) = 95 \quad (32)$$

feature a livello di canale.

Per ciascuna delle cinque regioni sono state ottenute quattro potenze medie e un theta/beta ratio:

$$5 \times (4 + 1) = 25 \quad (33)$$

feature regionali.

Il numero complessivo di predittori spettrali è quindi:

$$95 + 25 = 120. \quad (34)$$

La tabella finale contiene una riga per soggetto e 124 colonne: 120 feature predittive e quattro variabili descrittive, ID, Class, n_samples e duration_sec.

2.4 Esplorazione delle feature spettrali

Prima dell'addestramento dei classificatori è stata effettuata un'analisi esplorativa con due obiettivi principali:

1. descrivere la direzione e l'ampiezza delle differenze tra soggetti ADHD e controlli per ciascuna feature;
2. valutare il grado di ridondanza tra le feature estratte.

2.4.1 Test di Mann–Whitney U

Per confrontare i due gruppi è stato utilizzato il test di Mann-Whitney U, un test non parametrico per due campioni indipendenti.

La scelta di un test non parametrico è motivata dal fatto che le potenze EEG e i rapporti tra potenze possono presentare distribuzioni asimmetriche e valori estremi. Non è stata quindi assunta la normalità delle feature richiesta dal comune test t parametrico.

Per ogni feature, i valori dei soggetti ADHD e dei controlli vengono considerati congiuntamente, ordinati e trasformati in ranghi. Per il primo gruppo, la statistica può essere espressa come:

$$U_1 = R_1 - \frac{n_1(n_1 + 1)}{2}, \quad (35)$$

dove R_1 è la somma dei ranghi del primo gruppo e n_1 la sua numerosità. Analogamente si ottiene:

$$U_2 = n_1 n_2 - U_1. \quad (36)$$

Il test valuta se le osservazioni di uno dei due gruppi tendono a occupare ranghi sistematicamente più alti o più bassi rispetto all'altro gruppo.

È stato utilizzato un test a due code:

$$H_0 : \text{assenza di una differenza sistematica tra i gruppi}, \quad (37)$$

$$H_1 : \text{presenza di una differenza in una delle due direzioni}. \quad (38)$$

Non è stata imposta a priori una direzione, poiché, nonostante le ipotesi formulate sulla base della letteratura, il task attentivo poteva produrre differenze diverse da quelle osservate nelle registrazioni a riposo.

Un p-value piccolo indica che il risultato osservato è poco compatibile con l'ipotesi nulla. Un p-value elevato, al contrario, non dimostra che i gruppi siano identici, ma indica che i dati non forniscono evidenza sufficiente per rifiutare l'ipotesi nulla.

2.4.2 Cohen's d

La significatività statistica non fornisce una misura diretta dell'ampiezza della differenza. Per questo motivo, per ogni feature è stato calcolato anche Cohen's d :

$$d = \frac{\bar{x}_{\text{ADHD}} - \bar{x}_{\text{Control}}}{s_{\text{pooled}}}. \quad (39)$$

Nel notebook la deviazione standard combinata è stata calcolata come:

$$s_{\text{pooled}} = \sqrt{\frac{s_{\text{ADHD}}^2 + s_{\text{Control}}^2}{2}}. \quad (40)$$

Questa formulazione assegna lo stesso peso alle varianze dei due gruppi ed è appropriata nel presente dataset, nel quale le numerosità sono quasi identiche, rispettivamente 61 e 60 soggetti.

Con la convenzione adottata:

$$d > 0 \implies \bar{x}_{\text{ADHD}} > \bar{x}_{\text{Control}}, \quad (41)$$

mentre:

$$d < 0 \implies \bar{x}_{\text{Control}} > \bar{x}_{\text{ADHD}}. \quad (42)$$

Il valore assoluto $|d|$ descrive invece la grandezza della separazione standardizzata ed è stato utilizzato per ordinare le feature.

Mann–Whitney e Cohen's d forniscono informazioni complementari: il primo è basato sui ranghi e valuta l'evidenza statistica di una differenza, mentre il secondo descrive la differenza tra le medie in unità di deviazione standard.

2.4.3 Correzione per confronti multipli

Il test di Mann–Whitney è stato ripetuto per tutte le 120 feature spettrali. Applicando indipendentemente la soglia $p < 0.05$ a molti test, la probabilità di ottenere almeno alcuni risultati apparentemente significativi per effetto del caso aumenta.

Per controllare questo problema è stata applicata la procedura Benjamini–Hochberg per il controllo del *False Discovery Rate* (FDR) [?].

Indicando con m il numero totale di test, i p-value vengono ordinati:

$$p_{(1)} \leq p_{(2)} \leq \dots \leq p_{(m)}. \quad (43)$$

Ciascun p-value ordinato viene confrontato con:

$$\frac{i}{m}q, \quad (44)$$

dove i è la sua posizione nell'ordinamento e $q = 0.05$ è il livello di FDR scelto.

La procedura individua il massimo indice i^* per cui:

$$p_{(i^*)} \leq \frac{i^*}{m}q. \quad (45)$$

Vengono quindi rifiutate le ipotesi associate ai p-value fino a tale posizione. Nel notebook sono stati inoltre calcolati direttamente i p-value corretti, indicati come p_{FDR} , e sono state considerate significative le feature che soddisfacevano:

$$p_{\text{FDR}} < 0.05. \quad (46)$$

Il controllo FDR limita la proporzione attesa di falsi positivi tra i risultati dichiarati significativi; non garantisce invece che ogni singolo risultato significativo sia vero.

2.4.4 Correlazione di Spearman

Dopo il confronto tra i gruppi è stata analizzata la ridondanza tra le feature mediante il coefficiente di correlazione di Spearman.

A differenza dell'analisi precedente, questa procedura non verifica se una feature differisca tra ADHD e controlli. Valuta invece se i soggetti che presentano valori elevati in una feature tendano a presentare valori elevati, o bassi, anche in un'altra feature.

Spearman è definita come la correlazione di Pearson calcolata sui ranghi:

$$\rho_s = \text{corr}[R(X), R(Y)], \quad (47)$$

dove $R(X)$ e $R(Y)$ sono i ranghi delle osservazioni delle due variabili.

Nel caso in cui non siano presenti ranghi uguali, il coefficiente può anche essere espresso come:

$$\rho_s = 1 - \frac{6 \sum_{i=1}^n d_i^2}{n(n^2 - 1)}, \quad (48)$$

dove d_i è la differenza tra i ranghi delle due variabili per il soggetto i .

Il coefficiente assume valori compresi tra -1 e 1 :

- $\rho_s = 1$ indica un'associazione monotona positiva perfetta;
- $\rho_s = -1$ indica un'associazione monotona negativa perfetta;

- un valore vicino a zero indica l'assenza di una chiara associazione monotona.

Un valore nullo non esclude necessariamente la presenza di relazioni non monotone.

Spearman è stata preferita a Pearson per l'analisi delle feature spettrali perché è basata sui ranghi, non richiede normalità ed è meno sensibile ai valori estremi.

Le correlazioni sono state calcolate anche separatamente nei gruppi ADHD e Control, sia per le feature di canale sia per quelle regionali. Sono state inoltre studiate separatamente le correlazioni tra le potenze della stessa banda nei diversi canali.

2.5 Classificazione

Ogni soggetto è stato rappresentato mediante un vettore di feature e la classe diagnostica è stata utilizzata come variabile target:

$$y = \begin{cases} 0, & \text{Control,} \\ 1, & \text{ADHD.} \end{cases} \quad (49)$$

Sono stati considerati due classificatori:

- Random Forest, come modello capace di rappresentare relazioni non lineari e interazioni tra feature;
- Logistic Regression, come modello lineare di confronto.

2.5.1 Suddivisione dei dati e cross-validation

Prima di qualsiasi confronto tra feature set o ottimizzazione degli iperparametri, i 121 soggetti sono stati suddivisi in:

- training set, pari all'80% del campione;
- test set indipendente, pari al 20% del campione.

La divisione è stata eseguita mediante campionamento stratificato, in modo da mantenere proporzioni simili di ADHD e controlli nei due sottoinsiemi, utilizzando:

$$\text{random_state} = 42. \quad (50)$$

Il test set non è stato utilizzato per confrontare i feature set, scegliere il modello o ottimizzare gli iperparametri.

Sul solo training set è stata applicata una cross-validation stratificata a cinque fold, con mescolamento dei soggetti e `random_state=42`. In ciascuna iterazione, quattro fold sono stati utilizzati per l'addestramento e il quinto per la validazione. La procedura è stata ripetuta cinque volte, affinché ciascun fold fosse utilizzato una volta come validation set.

Dopo la selezione della configurazione migliore, il modello è stato addestrato nuovamente sull'intero training set e valutato una sola volta sul test set.

2.5.2 Metriche di valutazione

Sono state considerate le seguenti metriche:

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}, \quad (51)$$

$$\text{Recall} = \frac{TP}{TP + FN}, \quad (52)$$

$$\text{Precision} = \frac{TP}{TP + FP}, \quad (53)$$

$$F_1 = 2 \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}. \quad (54)$$

La balanced accuracy è la media del recall delle due classi:

$$\text{Balanced Accuracy} = \frac{\text{Sensitivity} + \text{Specificity}}{2}. \quad (55)$$

È stata inoltre calcolata la ROC-AUC, che misura la capacità del modello di assegnare punteggi più elevati ai soggetti ADHD rispetto ai controlli considerando tutte le possibili soglie decisionali.

2.5.3 Random Forest

La Random Forest è un metodo ensemble costituito da numerosi alberi decisionali.

Ogni albero viene addestrato su un campione del training set, ottenuto mediante estrazione casuale con reinserimento. Alcuni soggetti possono quindi comparire più volte nel campione di uno specifico albero, mentre altri possono non essere inclusi.

Inoltre, a ogni nodo viene valutato soltanto un sottoinsieme casuale delle feature. Questa seconda fonte di casualità riduce la correlazione tra gli alberi: alberi differenti tendono a costruire regole differenti e a commettere errori non perfettamente coincidenti.

La combinazione delle previsioni riduce soprattutto la varianza rispetto a un singolo albero. Nell'implementazione di `scikit-learn`, le probabilità di classe prodotte dai singoli alberi vengono mediate e viene selezionata la classe con probabilità media maggiore.

Per il confronto iniziale tra feature set è stata utilizzata una Random Forest con:

```
n_estimators = 500
max_depth = None
min_samples_leaf = 2
class_weight = "balanced"
random_state = 42
```

Il parametro `class_weight="balanced"` assegna pesi inversamente proporzionali alle numerosità delle classi. Sebbene il dataset sia quasi perfettamente bilanciato, il parametro è stato mantenuto per rendere il modello robusto alle piccole differenze presenti nei singoli fold.

Ottimizzazione degli iperparametri Il tuning è stato effettuato esclusivamente sul training set in due fasi.

Nella prima fase è stata utilizzata una `RandomizedSearchCV`, valutando 80 combinazioni estratte da uno spazio ampio:

```
n_estimators:      valori interi tra 200 e 1499
max_depth:         None, 3, 5, 7, 10, 15, 20, 30
min_samples_leaf:  valori interi tra 1 e 9
min_samples_split: valori interi tra 2 e 14
max_features:      "sqrt", "log2", None
```

La ricerca randomizzata permette di esplorare lo spazio degli iperparametri senza valutare esaustivamente tutte le possibili combinazioni.

Nella seconda fase è stata applicata una `GridSearchCV` locale costruita intorno ai valori migliori individuati nella prima ricerca. Questa fase ha permesso di esplorare sistematicamente una regione più ristretta dello spazio degli iperparametri.

Entrambe le ricerche hanno utilizzato la cross-validation stratificata a cinque fold e la balanced accuracy come funzione obiettivo.

Impurità di Gini e feature importance In un nodo contenente proporzioni p_k delle diverse classi, l'impurità di Gini è:

$$G(v) = 1 - \sum_{k=1}^K p_{k,v}^2. \quad (56)$$

Nel caso binario:

$$G(v) = 1 - p_{\text{ADHD},v}^2 - p_{\text{Control},v}^2. \quad (57)$$

L'impurità è nulla quando tutti i soggetti nel nodo appartengono alla stessa classe e raggiunge il massimo di 0.5 quando le due classi sono presenti in uguale proporzione.

Per uno split che divide un nodo padre v nei nodi figli v_L e v_R , la riduzione di impurità è:

$$\Delta G(v) = G(v) - \left[\frac{N_L}{N_v} G(v_L) + \frac{N_R}{N_v} G(v_R) \right]. \quad (58)$$

Il contributo dello split viene pesato per la proporzione di soggetti che raggiungono il nodo. Gli split vicini alla radice tendono quindi ad avere un peso maggiore rispetto a quelli che coinvolgono pochi soggetti.

L'importanza di una feature è ottenuta sommando le riduzioni pesate di impurità associate agli split che utilizzano quella feature, mediando il risultato su tutti gli alberi e normalizzando le importanze in modo che la loro somma sia uguale a uno.

La feature importance non indica la direzione dell'associazione e non deve essere interpretata come effetto causale. Inoltre, in presenza di feature correlate, più variabili possono essere utilizzate alternativamente nei diversi alberi e condividere la stessa importanza.

2.5.4 Logistic Regression

La Logistic Regression è stata utilizzata come modello lineare di confronto.

Il modello calcola una combinazione lineare delle feature:

$$z = w_0 + \sum_{j=1}^p w_j x_j, \quad (59)$$

e la trasforma mediante la funzione sigmoide:

$$P(y = 1 \mid \mathbf{x}) = \sigma(z) = \frac{1}{1 + e^{-z}}. \quad (60)$$

La standardizzazione è stata inserita all'interno di una pipeline:

$$z_j = \frac{x_j - \mu_j}{s_j}. \quad (61)$$

Durante ogni fold, media e deviazione standard sono state calcolate esclusivamente sui dati di training e successivamente applicate al validation set. Questa procedura evita che l'informazione contenuta nei dati di validazione influenzi il preprocessing.

Regolarizzazione e tuning È stata utilizzata una penalizzazione L_2 :

$$\lambda \sum_{j=1}^p w_j^2, \quad (62)$$

che riduce l'ampiezza dei coefficienti e limita la complessità del modello, senza effettuare normalmente una selezione esatta delle feature.

In `scikit-learn`, la forza della penalizzazione è regolata mediante il parametro:

$$C = \frac{1}{\lambda}. \quad (63)$$

Valori piccoli di C corrispondono quindi a una regolarizzazione più forte, mentre valori grandi corrispondono a una penalizzazione più debole.

Il parametro è stato ottimizzato mediante Grid Search sui valori:

$$C \in \{0.001, 0.01, 0.1, 1, 10, 100\}. \quad (64)$$

Sono stati utilizzati penalizzazione L_2 , solver `lbfgs`, `max_iter=5000` e `class_weight="balanced"`. La configurazione migliore è stata selezionata mediante balanced accuracy nella cross-validation stratificata a cinque fold.

2.6 Feature di functional connectivity

L'analisi spettrale descrive la quantità di potenza presente in ogni canale, ma non descrive direttamente come due segnali varino insieme nel tempo. Per ottenere una rappresentazione complementare è stata quindi calcolata la functional connectivity EEG.

Nel presente lavoro, la functional connectivity è definita come dipendenza statistica tra serie temporali registrate in canali o regioni differenti. Essa non dimostra l'esistenza di un collegamento anatomico diretto, non stabilisce una direzione dell'interazione e non permette di inferire causalità.

2.6.1 Filtraggio nelle singole bande

A partire dal segnale già preprocessato, per ciascun soggetto sono stati nuovamente isolati i segnali delle singole bande mediante un filtro Butterworth passa-banda di ordine quattro:

Banda	Intervallo
Delta	1–4 Hz
Theta	4–8 Hz
Alpha	8–13 Hz
Beta	13–30 Hz

Tabella 2: Bande utilizzate nell’analisi di functional connectivity.

Il filtro è stato applicato mediante `filtfilt`, eseguendo il filtraggio prima in avanti e poi all’indietro. Il risultato presenta un ritardo di fase netto nullo, caratteristica importante perché la connettività viene calcolata a partire dalle relazioni temporali tra i canali.

2.6.2 Correlazione di Pearson

Per due serie temporali $x(t)$ e $y(t)$, il coefficiente di Pearson è:

$$r_{xy} = \frac{\sum_{t=1}^T (x_t - \bar{x})(y_t - \bar{y})}{\sqrt{\sum_{t=1}^T (x_t - \bar{x})^2} \sqrt{\sum_{t=1}^T (y_t - \bar{y})^2}}. \quad (65)$$

Il coefficiente assume valori compresi tra -1 e 1 :

- $r > 0$: i due segnali tendono a variare nella stessa direzione;
- $r < 0$: i due segnali tendono a variare in direzioni opposte;
- $r \simeq 0$: non emerge una chiara relazione lineare a ritardo nullo.

Un valore prossimo a zero non esclude una relazione non lineare o una relazione caratterizzata da un ritardo temporale. Inoltre, correlazioni elevate possono essere influenzate dalla conduzione di volume, dalla scelta del riferimento e da sorgenti comuni.

2.6.3 Connettività tra canali

Per ciascuna banda è stata calcolata la correlazione di Pearson tra tutte le coppie uniche dei 19 canali.

Il numero di coppie è:

$$\binom{19}{2} = \frac{19 \cdot 18}{2} = 171. \quad (66)$$

Poiché sono state analizzate quattro bande, il numero totale di feature a livello di canale è:

$$171 \cdot 4 = 684. \quad (67)$$

Ogni feature rappresenta quindi la correlazione temporale a ritardo nullo tra due canali in una specifica banda. Un esempio è:

`F3_C3_theta_connectivity.`

2.6.4 Connettività regionale

Per costruire la rappresentazione regionale, dopo il filtraggio sono stati mediati campione per campione i segnali dei canali appartenenti alla stessa regione:

$$x_R(t) = \frac{1}{|R|} \sum_{c \in R} x_c(t). \quad (68)$$

Sono state così ottenute cinque serie temporali regionali: frontale, centrale, temporale, parietale e occipitale.

La correlazione di Pearson è stata quindi calcolata tra ciascuna coppia di serie regionali. Non è stata quindi calcolata la media delle correlazioni tra tutte le coppie di elettrodi delle due regioni: prima sono stati mediati i segnali e successivamente è stata calcolata la correlazione tra i segnali regionali risultanti.

Con cinque regioni si ottengono:

$$\binom{5}{2} = 10 \quad (69)$$

coppie per banda e:

$$10 \cdot 4 = 40 \quad (70)$$

feature regionali.

I feature set sono stati confrontati mediante la stessa procedura di classificazione descritta per le feature spettrali: split stratificato 80/20, cross-validation stratificata a cinque fold sul training set, selezione mediante balanced accuracy, tuning degli iperparametri e valutazione finale sul test set indipendente.

3 Risultati

3.1 Feature spettrali

3.1.1 Effect size delle differenze tra i gruppi

Per descrivere l'ampiezza delle differenze tra ADHD e Control è stato calcolato il Cohen's d per ciascuna delle 120 feature spettrali:

$$d = \frac{\mu_{\text{ADHD}} - \mu_{\text{Control}}}{s_{\text{pooled}}}. \quad (71)$$

Con questa definizione, un valore positivo indica che la feature è mediamente maggiore nel gruppo ADHD, mentre un valore negativo indica che è mediamente maggiore nel gruppo Control. Il valore assoluto di d descrive invece l'ampiezza della differenza tra i gruppi, indipendentemente dalla sua direzione.

Gli effect size sono stati rappresentati separatamente a livello di singolo canale e a livello regionale. Queste rappresentazioni descrivono la distribuzione spaziale delle differenze, ma non stabiliscono da sole se una feature sia statisticamente significativa.

Effect size a livello di singolo canale La Figura 1 mostra la distribuzione topografica del Cohen's d per la potenza delta, theta, alpha e beta e per il theta/beta ratio.




Figura 1: Distribuzione topografica degli effect size delle feature spettrali canale-livello. I valori negativi indicano feature mediamente maggiori nei controlli, mentre i valori positivi indicano feature mediamente maggiori nei soggetti ADHD. La stella identifica i canali significativi dopo correzione Benjamini–Hochberg. I colori tra gli elettrodi sono ottenuti per interpolazione e devono essere interpretati come supporto alla visualizzazione della distribuzione spaziale.

Nella banda delta prevalgono effect size negativi, indicando una potenza mediamente maggiore nei controlli nella maggior parte dei canali. Le differenze più ampie si osservano soprattutto in F7 ($d = -0.458$), Pz ($d = -0.420$), Cz ($d = -0.409$), P7 ($d = -0.408$), F3 ($d = -0.406$) e Fz ($d = -0.405$). Nei canali Fp2 e P8, invece, la differenza tra i gruppi è quasi nulla.

Anche nella banda theta gli effect size sono quasi tutti negativi. Le differenze maggiori si localizzano prevalentemente nelle aree parietali e posteriori, con Pz ($d = -0.556$), P7 ($d = -0.529$) e O1 ($d = -0.452$), ma sono presenti differenze moderate anche in F7 ($d = -0.451$), T7 ($d = -0.434$), P4 ($d = -0.414$) e Cz ($d = -0.401$). Nel dataset analizzato, la potenza theta risulta quindi tendenzialmente maggiore nei controlli e non nei soggetti ADHD.

Per la banda alpha gli effect size sono generalmente più piccoli. La maggior parte dei valori rimane negativa, ma le differenze sono meno marcate rispetto alle bande delta e theta. I valori più elevati in modulo si osservano in P7 ($d = -0.358$), Pz ($d = -0.275$) e Cz ($d = -0.270$), mentre nei canali occipitali e frontopolari le differenze sono prossime a zero.

La banda beta presenta un pattern più eterogeneo. In alcuni canali, come F4 ($d = 0.239$) e T8 ($d = 0.227$), la potenza è mediamente maggiore negli ADHD. In altri, soprattutto in P7 ($d = -0.302$), P4 ($d = -0.231$), P3 ($d = -0.208$) e Cz ($d = -0.191$), è invece maggiore nei controlli. Gli effect size rimangono comunque prevalentemente piccoli o moderati.

Il pattern più evidente riguarda il theta/beta ratio, per il quale quasi tutti i canali presentano Cohen's d negativo. La differenza più ampia si osserva in F4 ($d = -0.851$), seguita da T7 ($d = -0.634$), T8 ($d = -0.603$), P4 ($d = -0.578$) e O2 ($d = -0.450$). Il theta/beta ratio risulta quindi generalmente maggiore nei controlli, con una differenza particolarmente marcata nella regione frontale destra e nei canali temporali.

Tra tutti i valori rappresentati, soltanto il theta/beta ratio in F4 rimane statisticamente significativo dopo la correzione FDR, come indicato dalla stella nella topomap.

Effect size a livello regionale Gli effect size delle 25 feature regionali sono riportati nella Figura 2. Ogni cella rappresenta il Cohen's d calcolato per una determinata regione e una determinata feature spettrale.




Figura 2: Matrice degli effect size delle feature spettrali regionali. I valori negativi indicano valori medi maggiori nel gruppo Control, mentre i valori positivi indicano valori medi maggiori nel gruppo ADHD. Un eventuale asterisco indica la significatività dopo correzione FDR.

La matrice regionale conferma il quadro osservato a livello di singolo canale. La potenza delta presenta effect size negativi in tutte le regioni, con differenze più evidenti nelle regioni temporale ($d = -0.340$), frontale ($d = -0.335$) e parietale ($d = -0.335$).

Anche la potenza theta è maggiore nei controlli in tutte le regioni. La differenza più ampia si osserva nella regione parietale ($d = -0.490$), seguita dalle regioni centrale ($d = -0.427$), temporale ($d = -0.400$) e occipitale ($d = -0.369$).

Gli effect size della potenza alpha sono generalmente più piccoli. Le differenze maggiori si osservano nelle regioni parietale ($d = -0.277$) e centrale ($d = -0.252$), mentre nella regione occipitale il valore è praticamente nullo ($d = 0.008$).

La banda beta mostra nuovamente un andamento meno uniforme. La potenza beta è leggermente maggiore negli ADHD nelle regioni temporale ($d = 0.214$) e frontale ($d = 0.109$), mentre è maggiore nei controlli nelle regioni parietale ($d = -0.276$) e centrale ($d = -0.184$). Nella regione occipitale non emerge una differenza rilevante.

Il theta/beta ratio presenta effect size negativi in tutte le cinque regioni. La differenza più marcata riguarda la regione temporale ($d = -0.732$), seguita da quella frontale ($d = -0.472$), occipitale ($d = -0.411$) e centrale ($d = -0.387$). La regione parietale mostra invece una differenza più contenuta ($d = -0.241$).

Nonostante l'ampio effect size del theta/beta ratio temporale, nessuna feature regionale supera la soglia di significatività dopo correzione FDR. In particolare, il theta/beta

ratio temporale raggiunge un valore di $p_{\text{FDR}} \simeq 0.056$, vicino ma superiore alla soglia di 0.05.

Nel complesso, gli effect size mostrano quindi un andamento prevalentemente caratterizzato da valori più elevati nei controlli, soprattutto per la potenza theta e per il theta/beta ratio. Le differenze alpha risultano più deboli, mentre la banda beta presenta un pattern spaziale più eterogeneo, con valori maggiori negli ADHD in alcune posizioni frontali e temporali e valori maggiori nei controlli nelle aree centro-parietali.

3.1.2 Feature significative dopo correzione FDR

Gli effect size descritti nella sezione precedente indicano l'ampiezza delle differenze, ma non la loro significatività statistica. Dopo la correzione Benjamini–Hochberg applicata ai 120 confronti, una sola feature rimane statisticamente significativa:

$$\text{F4_theta_beta_ratio}, \quad p_{\text{FDR}} = 0.0158. \quad (72)$$

Per questa feature, il valore medio è pari a 1.444 nel gruppo ADHD e a 2.225 nel gruppo Control, con Cohen's $d = -0.851$.




Figura 3: Distribuzione del theta/beta ratio in F4, unica feature significativa dopo correzione Benjamini–Hochberg.

Le altre feature con effect size moderato o elevato non superano la correzione per confronti multipli. Ciò indica che, nonostante siano presenti tendenze descrittive diffuse, l'evidenza statistica più robusta è circoscritta al theta/beta ratio del canale F4.

3.1.3 Ridondanza tra le feature spettrali

Le correlazioni di Spearman sono state calcolate separatamente nei gruppi ADHD e Control per valutare la ridondanza tra le feature.

Tra le associazioni canale-livello più elevate si osservano, nel gruppo ADHD, la correlazione tra la potenza alpha in F4 e Fz ($\rho = 0.886$) e quella tra la potenza beta in F3 e Fz ($\rho = 0.881$). Nel gruppo Control, la correlazione più elevata riguarda il theta/beta ratio in F3 e F4 ($\rho = 0.890$), seguita dalla potenza delta in C4 e Cz ($\rho = 0.885$).




Figura 4: Reti delle correlazioni di Spearman tra le potenze calcolate nei diversi canali, rappresentate separatamente per banda e gruppo. Sono mostrate le associazioni che superano la soglia stabilita in almeno uno dei due gruppi.

Le distribuzioni delle 171 correlazioni possibili tra i 19 canali sono riportate nella Figura 5. La maggior parte delle associazioni è positiva. Nelle bande delta e theta, e in misura minore nel theta/beta ratio, la distribuzione dei controlli appare spostata verso coefficienti più elevati. Le distribuzioni alpha e beta risultano invece maggiormente sovrapposte.




Figura 5: Distribuzione delle correlazioni di Spearman canale-livello, separatamente per banda e gruppo.

L'analisi regionale mostra un quadro analogo, sebbene basato soltanto su dieci coppie di regioni per ogni banda. Anche dopo l'aggregazione regionale le associazioni rimangono prevalentemente positive e generalmente elevate.




Figura 6: Distribuzione delle correlazioni di Spearman tra feature regionali, separatamente per banda e gruppo.

enti. Il risultato evidenzia una marcata ridondanza interna del feature set spettrale.

3.2 Classificazione basata sulle feature spettrali

3.2.1 Confronto dei feature set mediante Random Forest

Sono stati confrontati tre insiemi di feature: il set completo di 120 feature, le 95 feature canale-livello e le 25 feature regionali.

Feature set	N	Accuracy	Balanced acc.	Precision	Recall	F1	ROC-AUC
Tutte le feature	120	0.605	0.604	0.593	0.709	0.642	0.608
Canale-livello	95	0.595	0.593	0.598	0.687	0.634	0.625
Regionali	25	0.604	0.603	0.599	0.667	0.628	0.635

Tabella 3: Performance medie in cross-validation stratificata a cinque fold dei tre feature set spettrali valutati mediante Random Forest.

Le differenze tra il set completo e quello regionale sono molto piccole. Poiché il criterio di selezione era la balanced accuracy, è stato selezionato il set completo di 120 feature, che raggiunge 0.604 rispetto a 0.603 del set regionale.




Figura 7: Confronto delle metriche di cross-validation della Random Forest sui tre feature set spettrali.

3.2.2 Random Forest sul feature set completo

Dopo Randomized Search e Grid Search locale, gli iperparametri selezionati sono:

Iperparametro	Valore
n_estimators	1019
max_depth	None
min_samples_leaf	1
min_samples_split	4
max_features	None

Tabella 4: Iperparametri selezionati per la Random Forest applicata alle 120 feature spettrali.

La balanced accuracy ottenuta durante il tuning è pari a 0.638. Le prestazioni sul test set indipendente sono riportate nella Tabella 5.

Metrica	Valore
N feature	120
Accuracy	0.640
Balanced accuracy	0.638
Precision ADHD	0.643
Recall ADHD	0.692
F1-score ADHD	0.667
ROC-AUC	0.731

Tabella 5: Prestazioni della Random Forest sul feature set spettrale completo, valutate sul test set indipendente.




Figura 8: Confusion matrix della Random Forest basata sulle 120 feature spettrali.

La confusion matrix contiene 7 controlli e 9 soggetti ADHD correttamente classificati. Sono presenti 5 falsi positivi e 4 falsi negativi. Le prestazioni risultano quindi moderate e relativamente bilanciate tra le due classi.




Figura 9: Curva ROC della Random Forest basata sulle 120 feature spettrali.

3.2.3 Feature importance spettrale

La feature più importante è il theta/beta ratio in F4, che presenta un'importanza nettamente superiore rispetto alle altre variabili. Seguono il TBR in F3, la potenza alpha in Cz, la potenza theta in Pz e il TBR parietale.




Figura 10: Prime dieci feature spettrali ordinate secondo l'importanza basata sulla riduzione media dell'impurità.

La prevalenza di feature TBR e theta tra le prime posizioni è coerente con gli effect size osservati nell'analisi univariata. Tuttavia, l'importanza non deve essere interpretata come evidenza causale e può essere distribuita tra feature fortemente correlate.

3.2.4 Riduzione del feature set mediante correlazione

A partire dalla feature importance della Random Forest e dalle correlazioni di Spearman tra le variabili, è stata applicata una procedura di riduzione del feature set.

Le feature sono state inizialmente ordinate in base alla loro importanza. Procedendo secondo tale ordinamento, una feature veniva mantenuta soltanto se non presentava una correlazione superiore alla soglia considerata con una variabile già selezionata. In questo modo sono state conservate prioritariamente le feature maggiormente utilizzate dal modello, eliminando parte dell'informazione ridondante.

Sono state confrontate quattro soglie di correlazione per ridurre la ridondanza delle 120 feature.

Soglia	N	Accuracy	Balanced acc.	Precision	Recall	F1	ROC-AUC
0.70	35	0.584	0.582	0.573	0.687	0.624	0.648
0.75	52	0.616	0.617	0.602	0.731	0.658	0.661
0.80	75	0.594	0.592	0.593	0.687	0.632	0.640
0.85	94	0.563	0.562	0.574	0.624	0.591	0.618

Tabella 6: Confronto in cross-validation delle soglie utilizzate per la riduzione basata sulla correlazione di Spearman.

La soglia selezionata è pari a 0.75, poiché presenta la balanced accuracy media più elevata e mantiene 52 delle 120 feature originali.

Sul feature set ridotto è stata quindi ripetuta la procedura di tuning mediante Randomized Search e Grid Search locale. La migliore balanced accuracy ottenuta in cross-validation durante il tuning è pari a 0.657.

Gli iperparametri selezionati sono riportati nella Tabella 7.

Iperparametro	Valore
n_estimators	143
max_depth	15
min_samples_leaf	3
min_samples_split	10
max_features	log2

Tabella 7: Iperparametri selezionati per la Random Forest applicata al feature set spettrale ridotto a 52 variabili.

Le prestazioni ottenute sul test set indipendente sono riportate nella Tabella 8.

Metrica	Valore
N feature	52
Accuracy	0.680
Balanced accuracy	0.676
Precision ADHD	0.667
Recall ADHD	0.769
F1-score ADHD	0.714
ROC-AUC	0.750

Tabella 8: Prestazioni finali della Random Forest applicata al feature set spettrale ridotto.




Figura 11: Confusion matrix della Random Forest applicata al feature set spettrale ridotto a 52 variabili.




Figura 12: Curva ROC della Random Forest applicata al feature set spettrale ridotto a 52 variabili.

Il modello identifica correttamente 7 controlli su 12 e 10 soggetti ADHD su 13. Sono quindi presenti 5 controlli classificati come ADHD e 3 soggetti ADHD classificati come controlli.

Rispetto al feature set completo, il set ridotto migliora l'accuracy da 0.640 a 0.680, la balanced accuracy da 0.638 a 0.676 e la ROC-AUC da 0.731 a 0.750, pur utilizzando meno della metà delle feature originali.

Il miglioramento rimane contenuto, ma suggerisce che la rimozione di parte delle variabili fortemente correlate abbia ridotto la ridondanza senza eliminare l'informazione discriminante principale.

3.2.5 Classificazione mediante il theta/beta ratio

Per valutare direttamente quanta informazione discriminante fosse contenuta nel theta/beta ratio, sono stati confrontati tre insiemi di feature:

- i 5 TBR regionali;
- i 19 TBR calcolati sui singoli canali;
- l'insieme completo dei 24 TBR regionali e canale-livello.

Il confronto è stato effettuato sul training set mediante cross-validation stratificata a cinque fold, utilizzando una Random Forest con configurazione iniziale comune.

Feature set	N	Accuracy	Balanced acc.	Precision	Recall	F1	ROC-AUC
TBR regionale	5	0.645	0.648	0.630	0.711	0.650	0.663
TBR canale-livello	19	0.656	0.658	0.629	0.813	0.702	0.707
Tutti i TBR	24	0.636	0.637	0.623	0.731	0.658	0.689

Tabella 9: Confronto in cross-validation dei tre feature set basati esclusivamente sul theta/beta ratio. Le metriche rappresentano le medie ottenute nei cinque fold.

Il set canale-livello presenta la balanced accuracy media più elevata, pari a 0.658, ed è stato quindi selezionato per il tuning finale. Il risultato suggerisce che mantenere separata l'informazione dei singoli elettrodi sia più utile rispetto alla sintesi regionale, probabilmente perché il TBR presenta differenze spazialmente localizzate che possono attenuarsi quando i canali vengono mediati.

Sui 19 TBR canale-livello è stata applicata la stessa procedura di ottimizzazione utilizzata per gli altri modelli Random Forest: una Randomized Search seguita da una Grid Search locale. La metrica ottimizzata è stata la balanced accuracy, calcolata mediante cross-validation stratificata sul solo training set.

Gli iperparametri selezionati sono riportati nella Tabella.

Iperparametro	Valore
n_estimators	5
max_depth	None
min_samples_leaf	1
min_samples_split	9
max_features	618

Tabella 10: Iperparametri selezionati per la Random Forest applicata ai 19 theta/beta ratio canale-livello.

La migliore balanced accuracy ottenuta durante il tuning è pari a 0.701. Dopo la selezione degli iperparametri, il modello è stato riaddestrato sull'intero training set e valutato una sola volta sul test set indipendente.

Metrica	Valore
N feature	19
Accuracy	0.720
Balanced accuracy	0.712
Precision ADHD	0.667
Recall ADHD	0.923
F1-score ADHD	0.774
ROC-AUC	0.737

Tabella 11: Prestazioni della Random Forest basata sui 19 theta/beta ratio canale-livello, valutata sul test set indipendente.




Figura 13: Confusion matrix della Random Forest basata sui 19 theta/beta ratio canale-livello.




Figura 14: Curva ROC della Random Forest basata sui 19 theta/beta ratio canale-livello.

Il modello identifica correttamente 12 soggetti ADHD su 13, ma soltanto 6 controlli su 12. Sono quindi presenti cinque controlli classificati erroneamente come ADHD e un solo soggetto ADHD classificato come controllo.

Il recall ADHD molto elevato, pari a 0.923, mostra che il TBR contiene informazione utile per individuare i soggetti ADHD. Tuttavia, la specificità verso i controlli è pari al 50%. Il modello tende quindi ad assegnare con eccessiva frequenza la classe ADHD.

Questi risultati indicano che il theta/beta ratio è informativo nel campione analizzato, ma non fornisce una separazione sufficientemente equilibrata per essere considerato un marker diagnostico autonomo.

3.2.6 Logistic Regression sulle feature spettrali

La Logistic Regression è stata applicata separatamente a tre rappresentazioni delle feature spettrali:

- il feature set completo, costituito da 120 variabili;
- il feature set ridotto mediante correlazione, costituito da 52 variabili;
- i 19 theta/beta ratio canale-livello.

Per ciascun feature set è stato costruito e ottimizzato un modello indipendente. Non è stato quindi effettuato un confronto preliminare in cross-validation finalizzato alla selezione di un unico insieme di feature.

In tutti i modelli, la standardizzazione è stata inclusa all'interno di una pipeline, in modo che media e deviazione standard fossero calcolate esclusivamente sui dati di training di ciascun fold.

La Logistic Regression è stata utilizzata con penalizzazione L2, solver `lbfgs`, `max_iter=5000` e `class_weight=balanced`. Per ciascun feature set, il parametro di regolarizzazione C è stato ottimizzato separatamente mediante Grid Search con cross-validation stratificata a cinque fold, utilizzando la balanced accuracy come metrica di selezione.

Feature spettrali complete Il primo modello è stato addestrato utilizzando tutte le 120 feature spettrali, comprendenti le potenze di banda e i theta/beta ratio calcolati a livello di singolo canale e a livello regionale.

La Grid Search ha selezionato un valore di $C = 0.001$. Poiché in scikit-learn C è inversamente proporzionale alla forza della regolarizzazione, questo valore corrisponde a una penalizzazione L2 particolarmente forte.

La balanced accuracy media ottenuta durante il tuning è pari a 0.572.

Parametro	Valore
N feature	120
C	0.001
penalty	l2
solver	lbfgs
max_iter	5000
class_weight	balanced
Balanced accuracy CV	0.572

Tabella 12: Configurazione ottimale della Logistic Regression applicata alle 120 feature spettrali complete.

Dopo il tuning, il modello è stato riaddestrato sull'intero training set e valutato sul test set indipendente.

Metrica	Valore
N feature	120
Accuracy	0.480
Balanced accuracy	0.468
Precision ADHD	0.500
Recall ADHD	0.769
F1-score ADHD	0.606
ROC-AUC	0.545

Tabella 13: Prestazioni sul test set della Logistic Regression basata sulle 120 feature spettrali complete.




Figura 15: Confusion matrix della Logistic Regression basata sulle 120 feature spettrali complete.




Figura 16: Curva ROC della Logistic Regression basata sulle 120 feature spettrali complete.

Il modello classifica correttamente 10 soggetti ADHD su 13, ma soltanto 2 controlli su 12. Sono quindi presenti 10 falsi positivi e 3 falsi negativi.

Il recall ADHD relativamente elevato deriva dalla tendenza del modello ad assegnare molti soggetti alla classe ADHD. La balanced accuracy inferiore a 0.5 e la ROC-AUC pari a 0.545 indicano che il feature set completo non consente alla Logistic Regression di ottenere una separazione efficace e bilanciata tra le due classi.

Feature spettrali ridotte Il secondo modello è stato applicato alle 52 feature conservate dopo la procedura di riduzione basata sulla feature importance e sulla correlazione di Spearman.

Per questo insieme, la Grid Search ha selezionato $C = 100$, valore che corrisponde a una penalizzazione L2 molto debole. La balanced accuracy media ottenuta in cross-validation è pari a 0.583.

Parametro	Valore
N feature	52
C	100
penalty	l2
solver	lbfgs
max_iter	5000
class_weight	balanced
Balanced accuracy CV	0.583

Tabella 14: Configurazione ottimale della Logistic Regression applicata alle 52 feature spettrali ridotte.

Le prestazioni ottenute sul test set indipendente sono riportate nella Tabella 15.

Metrica	Valore
N feature	52
Accuracy	0.520
Balanced accuracy	0.519
Precision ADHD	0.538
Recall ADHD	0.538
F1-score ADHD	0.538
ROC-AUC	0.538

Tabella 15: Prestazioni sul test set della Logistic Regression applicata alle 52 feature spettrali ridotte.




Figura 17: Confusion matrix della Logistic Regression applicata alle 52 feature spettrali ridotte.




Figura 18: Curva ROC della Logistic Regression applicata alle 52 feature spettrali ridotte.

Il modello classifica correttamente 6 controlli su 12 e 7 soggetti ADHD su 13. Sono quindi presenti 6 falsi positivi e 6 falsi negativi.

La riduzione delle feature produce un comportamento più equilibrato tra le due classi rispetto al modello completo, ma le prestazioni rimangono prossime al caso. La balanced

accuracy pari a 0.519 e la ROC-AUC pari a 0.538 indicano che la rimozione della ridondanza non è sufficiente a rendere linearmente separabili i due gruppi mediante questo insieme di potenze e rapporti.

Theta/beta ratio canale-livello Il terzo modello è stato addestrato utilizzando esclusivamente i 19 theta/beta ratio calcolati sui singoli canali.

La Grid Search ha selezionato $C = 0.1$, corrispondente a una regolarizzazione di intensità intermedia rispetto ai due modelli precedenti. La balanced accuracy media ottenuta in cross-validation è pari a 0.643.

Parametro	Valore
N feature	19
C	0.1
penalty	l2
solver	lbfgs
max_iter	5000
class_weight	balanced
Balanced accuracy CV	0.643

Tabella 16: Configurazione ottimale della Logistic Regression basata sui 19 theta/beta ratio canale-livello.

Le prestazioni ottenute sul test set sono riportate nella Tabella 17.

Metrica	Valore
N feature	19
Accuracy	0.760
Balanced accuracy	0.756
Precision ADHD	0.733
Recall ADHD	0.846
F1-score ADHD	0.786
ROC-AUC	0.731

Tabella 17: Prestazioni sul test set della Logistic Regression basata sui 19 theta/beta ratio canale-livello.




Figura 19: Confusion matrix della Logistic Regression basata sui 19 theta/beta ratio canale-livello.




Figura 20: Curva ROC della Logistic Regression basata sui 19 theta/beta ratio canale-livello.

Il modello classifica correttamente 8 controlli su 12 e 11 soggetti ADHD su 13. Sono quindi presenti 4 falsi positivi e 2 falsi negativi.

La sensibilità verso la classe ADHD è pari a 0.846, mentre la specificità verso i controlli è pari a 0.667. Il modello mantiene quindi una maggiore capacità di riconoscere i soggetti ADHD, ma presenta un comportamento più equilibrato rispetto alla Random Forest basata sullo stesso feature set.

Tra i tre modelli di Logistic Regression, quello basato sui theta/beta ratio ottiene le prestazioni più elevate. Questo confronto è puramente descrittivo dei risultati ottenuti: ciascun modello è stato ottimizzato indipendentemente sul training set e non è stato utilizzato il test set per selezionare il feature set.

Le prestazioni inferiori dei modelli completo e ridotto possono dipendere dall'elevata dimensionalità, dalla forte correlazione tra le feature e dalla presenza di relazioni che non possono essere rappresentate efficacemente mediante una singola frontiera lineare. Il set dei TBR è invece più compatto e sembra contenere un pattern di separazione maggiormente compatibile con un modello lineare.

3.3 Feature di functional connectivity

3.3.1 Descrizione globale della connettività canale-livello

Per confrontare globalmente l'organizzazione della functional connectivity nei due gruppi, sono state rappresentate le connettività separatamente per le bande delta, theta, alpha e beta.

Con 19 canali EEG, per ciascuna banda sono disponibili:

$$\binom{19}{2} = 171 \quad (73)$$

coppie uniche di elettrodi. Nella Figura 21 vengono mostrate tutte le 171 connessioni, senza applicare una selezione basata sulla loro intensità, sulla feature importance o sulla differenza tra i gruppi.

Per ogni soggetto, la connettività tra una coppia di canali è stata descritta mediante il coefficiente di correlazione di Pearson calcolato tra i segnali filtrati nella stessa banda di frequenza.

Ogni soggetto mantiene il proprio valore di connettività, utilizzato successivamente come feature per la classificazione. Soltanto per costruire le rappresentazioni grafiche dei due gruppi, i coefficienti relativi alla stessa connessione sono stati riassunti in un unico valore medio per il gruppo Control e in un unico valore medio per il gruppo ADHD.

Poiché i coefficienti di correlazione sono limitati tra -1 e 1 , la media di gruppo è stata calcolata mediante la trasformazione di Fisher. Questa operazione è stata utilizzata esclusivamente per la visualizzazione descrittiva e non ha modificato i valori individuali impiegati nei modelli di classificazione.

Questa è la trasformazione di Fisher:

$$z_s = \operatorname{arctanh}(r_s), \quad (74)$$

successivamente sono stati mediati e infine riportati nella scala originale:

$$\bar{r} = \tanh \left(\frac{1}{N} \sum_{s=1}^N z_s \right). \quad (75)$$




Figura 21: Connettività funzionale media di Pearson a livello di singolo canale nei gruppi Control e ADHD. Le colonne corrispondono alle bande delta, theta, alpha e beta; la prima riga rappresenta il gruppo Control e la seconda il gruppo ADHD. Per ogni pannello sono mostrate tutte le 171 coppie uniche tra i 19 canali. Il colore delle connessioni indica il segno della correlazione media: il rosso rappresenta correlazioni positive, il blu correlazioni negative e i colori prossimi al bianco indicano valori vicini a zero. Lo spessore della linea è proporzionale al valore assoluto del coefficiente medio. I colori disposti lungo la circonferenza identificano la regione di appartenenza degli elettrodi.

Le mappe mostrano una struttura di connettività complessa e distribuita in entrambi i gruppi. Sono presenti contemporaneamente correlazioni positive e negative, con intensità variabile in funzione della banda e della coppia di canali considerata.

Dal confronto visivo non emerge un semplice aumento o una semplice riduzione globale della connettività nel gruppo ADHD. Le configurazioni generali dei due gruppi appaiono in parte simili, mentre le differenze sembrano riguardare specifici sottoinsiemi di connessioni e dipendere dalla banda di frequenza.

Questo risultato è coerente con il fatto che la classificazione non sia guidata da una singola misura media di connettività, ma da una combinazione multivariata di connessioni. In particolare, la successiva analisi della feature importance identifica come maggiormente informative alcune connessioni centro-parietali nella banda beta, insieme a connessioni alpha e theta distribuite in altre posizioni.

La rappresentazione completa permette di valutare il pattern globale, ma la sua elevata densità rende difficile individuare visivamente le singole differenze tra i gruppi. La figura deve quindi essere interpretata come descrizione complessiva della connettività media e non come test statistico delle singole connessioni. Il colore o lo spessore di una linea non indicano che la differenza tra ADHD e Control sia statisticamente significativa.

3.3.2 Confronto dei feature set di connettività

Sono stati confrontati il set completo di 724 connessioni, le 684 connessioni canale-livello e le 40 connessioni regionali.

Feature set	N	Accuracy	Balanced acc.	Precision	Recall	F1	ROC-AUC
Tutte le connessioni	724	0.677	0.672	0.662	0.724	0.680	0.732
Canale-livello	684	0.667	0.664	0.668	0.689	0.667	0.751
Regionali	40	0.594	0.593	0.605	0.624	0.601	0.639

Tabella 18: Prestazioni medie in cross-validation della Random Forest sui feature set di functional connectivity.

Il set completo presenta la balanced accuracy media più elevata ed è stato quindi selezionato per il tuning finale. Le connessioni canale-livello ottengono invece la ROC-AUC media più elevata, mentre il set regionale perde una parte rilevante dell'informazione discriminativa.

3.3.3 Random Forest sulla functional connectivity

Gli iperparametri selezionati sono:

Iperparametro	Valore
n_estimators	984
max_depth	15
min_samples_leaf	2
min_samples_split	11
max_features	None

Tabella 19: Iperparametri della Random Forest applicata alle 724 feature di connettività.

La balanced accuracy ottenuta durante il tuning è pari a 0.707. Sul test set indipendente il modello ottiene:

Metrica	Valore
N feature	724
Accuracy	0.960
Balanced accuracy	0.958
Precision ADHD	0.929
Recall ADHD	1.000
F1-score ADHD	0.963
ROC-AUC	0.968

Tabella 20: Prestazioni finali della Random Forest basata sul set completo di functional connectivity.




Figura 22: Confusion matrix della Random Forest basata sulle 724 feature di functional connectivity.

Il modello classifica correttamente tutti i 13 soggetti ADHD e 11 dei 12 controlli. L'unico errore consiste quindi in un controllo classificato come ADHD.




Figura 23: Curva ROC della Random Forest basata sulla functional connectivity.

3.3.4 Feature importance delle connessioni

Le prime connessioni ordinate per feature importance sono riportate nella Tabella 21.

Feature	Importanza
C3_P3_beta_connectivity	0.0629
O1_Pz_alpha_connectivity	0.0399
C4_P4_beta_connectivity	0.0366
C3_Cz_beta_connectivity	0.0226
P4_Cz_beta_connectivity	0.0214
Fp1_F3_theta_connectivity	0.0205
F3_Fz_beta_connectivity	0.0190
P3_Pz_beta_connectivity	0.0180
F3_Fz_theta_connectivity	0.0154
C4_O2_beta_connectivity	0.0145

Tabella 21: Prime dieci feature di functional connectivity secondo la feature importance della Random Forest.




Figura 24: Prime quindici connessioni ordinate secondo l'importanza nella Random Forest.

Tra le feature più importanti prevalgono connessioni canale-livello della banda beta, soprattutto tra posizioni centrali e parietali. Compaiono inoltre connessioni alpha e theta. Il modello non sembra quindi dipendere da una singola banda o da una singola regione, ma da un pattern distribuito.

3.3.5 Logistic Regression sulla functional connectivity

La Logistic Regression è stata valutata sullo stesso set completo di 724 feature. Il parametro ottimale è risultato pari a $C = 100$, con balanced accuracy in cross-validation pari a 0.734.

Metrica	Valore
N feature	724
Accuracy	0.840
Balanced accuracy	0.843
Precision ADHD	0.909
Recall ADHD	0.769
F1-score ADHD	0.833
ROC-AUC	0.929

Tabella 22: Prestazioni della Logistic Regression basata sulle 724 feature di functional connectivity.




Figura 25: Confusion matrix della Logistic Regression basata sulla functional connectivity.

La Logistic Regression classifica correttamente 11 controlli su 12 e 10 soggetti ADHD su 13. Le prestazioni sono inferiori rispetto alla Random Forest sul test set, ma rimangono superiori a quelle ottenute con le rappresentazioni spettrali.

4 Conclusioni




Figura 26: Confronto complessivo delle metriche di classificazione sul test set indipendente per le differenti rappresentazioni EEG e i modelli considerati. Precision, recall e F1-score si riferiscono alla classe ADHD.

Nel complesso, la functional connectivity risulta la rappresentazione più informativa nel dataset analizzato. La Random Forest applicata alle 724 connessioni ottiene il risultato migliore, suggerendo che possano essere utili relazioni non lineari o interazioni tra le connessioni. Anche la Logistic Regression raggiunge comunque prestazioni elevate, indicando che una parte consistente dell'informazione discriminante è rappresentabile linearmente.

Tra le feature spettrali, il theta/beta ratio canale-livello è il set più efficace, soprattutto in termini di sensibilità verso la classe ADHD. Tuttavia, la minore specificità della Random Forest basata sul TBR e l'eterogeneità degli effect size confermano che tale indice non può essere interpretato come marker diagnostico autonomo.

Il risultato della Random Forest sulla connettività deve essere interpretato con cautela. L'accuracy del 96% corrisponde a 24 soggetti correttamente classificati su un test set di soli 25 partecipanti. Inoltre, la balanced accuracy ottenuta in cross-validation durante il tuning è pari a circa 0.707, molto inferiore al valore osservato sul test. Questa differenza indica che le prestazioni finali possono dipendere favorevolmente dallo specifico split e non costituiscono ancora una stima stabile della generalizzazione su nuovi campioni.

4.1 Sintesi dei risultati

L'obiettivo del presente lavoro era confrontare differenti rappresentazioni dello stesso segnale EEG per distinguere bambini con ADHD e soggetti di controllo. Sono state considerate, da un lato, le caratteristiche spettrali locali, comprendenti le potenze nelle bande delta, theta, alpha e beta e il theta/beta ratio; dall'altro, la functional connectivity, descritta attraverso la correlazione di Pearson tra segnali registrati in canali e regioni differenti.

Il risultato complessivo più importante è che le feature di functional connectivity hanno fornito prestazioni nettamente superiori rispetto alle sole caratteristiche spettrali. Il miglior modello è risultato essere la Random Forest applicata al set completo di 724 feature di connettività, comprendente sia le connessioni tra singoli canali sia quelle tra segnali regionali. La confusion matrix mostra che sono stati classificati correttamente tutti i 13 soggetti ADHD e 11 dei 12 controlli. L'unico errore corrisponde quindi a un soggetto di controllo classificato come ADHD.

La Logistic Regression applicata alle stesse 724 feature di connettività ha ottenuto prestazioni inferiori, ma comunque elevate.

Nel presente esperimento, quindi, la Random Forest risulta superiore alla Logistic Regression quando entrambe ricevono l'intero insieme delle connessioni. Questo suggerisce che la separazione tra i due gruppi possa dipendere non soltanto da una combinazione lineare delle singole connessioni, ma anche da interazioni e relazioni non lineari tra esse. Tale conclusione rimane tuttavia limitata allo specifico campione e allo specifico test set utilizzati.

Le rappresentazioni spettrali hanno invece prodotto prestazioni più moderate. Il modello Random Forest applicato alle 120 feature spettrali complete ha ottenuto una balanced accuracy pari a 0.638, mentre la riduzione basata sulla correlazione, che ha conservato 52 feature, ha aumentato la balanced accuracy a 0.676. La riduzione della ridondanza ha quindi prodotto un modello più compatto e leggermente più efficace, ma il miglioramento non è stato sufficiente a colmare la distanza rispetto alla functional connectivity.

Tra le rappresentazioni spettrali, il theta/beta ratio calcolato sui 19 canali è risultato il set più informativo. La Logistic Regression basata esclusivamente sul TBR ha raggiunto una balanced accuracy pari a 0.756, mentre la Random Forest ha raggiunto 0.712. Il

TBR contiene quindi informazione utile, ma non ha raggiunto le prestazioni delle feature di connettività e non può essere considerato un indicatore diagnostico autonomo.

4.2 Caratterizzazione dei gruppi nel dataset analizzato

L'analisi univariata delle feature spettrali non ha confermato l'ipotesi classica di un theta/beta ratio sistematicamente più elevato nei soggetti ADHD. Al contrario, gli effect size del TBR sono risultati prevalentemente negativi, indicando valori medi maggiori nel gruppo di controllo.

Dopo la correzione Benjamini–Hochberg per confronti multipli, l'unica feature statisticamente significativa è risultata:

$$\text{F4_theta_beta_ratio}, \quad d = -0.851, \quad p_{\text{FDR}} = 0.0158. \quad (76)$$

Il theta/beta ratio in F4 è quindi mediamente inferiore nei soggetti ADHD rispetto ai controlli. Anche il TBR temporale e le potenze theta in posizioni parietali presentano effect size negativi, sebbene non rimangano significativi dopo la correzione per confronti multipli.

Nel campione analizzato, la differenza nel TBR sembra dipendere soprattutto da una minore potenza theta nel gruppo ADHD, mentre le differenze nella banda beta risultano meno uniformi. L'alpha mostra generalmente effect size contenuti e sembra discriminare poco i due gruppi quando viene considerata soltanto come potenza locale.

Questi risultati non implicano che la theta o il TBR siano generalmente inferiori nell'ADHD. La registrazione è stata effettuata durante un compito di attenzione visiva e non in condizioni di riposo. Durante un compito, l'attività theta può riflettere processi di controllo cognitivo, monitoraggio e mantenimento dell'attenzione, oltre che sonnolenza o ridotta vigilanza. La direzione osservata deve pertanto essere interpretata come una caratteristica dello specifico dataset e della specifica condizione sperimentale.

L'analisi della functional connectivity mostra un quadro più distribuito. Non emerge una semplice riduzione o un semplice aumento globale della connettività nei soggetti ADHD. Le differenze dipendono dalla banda e dalla coppia di elettrodi considerata.

Nei controlli risultano descrittivamente più forti diverse connessioni fronto-centrali destre, tra cui **F4-Cz** nelle bande delta, theta e alpha e **F4-C4** nelle stesse bande. Nei soggetti ADHD risultano invece più elevate alcune connessioni centro-parietali, in particolare:

$$\text{C3-P3} \quad \text{e} \quad \text{C4-P4}, \quad (77)$$

soprattutto nelle bande alpha e beta. Anche la connessione frontopolare-frontale **Fp1-F3** risulta maggiore negli ADHD in più bande.

Le feature maggiormente utilizzate dalla Random Forest comprendono infatti:

- C3-P3 nella banda beta;
- O1-Pz nella banda alpha;
- C4-P4 nella banda beta;
- C3-Cz e P4-Cz nella banda beta;
- Fp1-F3 nella banda theta.

Nel presente studio, i soggetti ADHD sembrano quindi caratterizzati da una differente organizzazione delle relazioni temporali tra segnali, soprattutto lungo connessioni centro-parietali e fronto-frontali. I controlli mostrano invece correlazioni più elevate in alcune connessioni fronto-centrali. Queste osservazioni sono descrittive e non dimostrano l'esistenza di connessioni anatomiche dirette, né consentono di attribuire una direzione causale all'interazione.

Il fatto che la functional connectivity discrimini i gruppi meglio delle potenze spettrali suggerisce che, durante il compito di attenzione visiva, la differenza più informativa non riguardi soltanto quanta attività sia presente in una determinata banda, ma come l'attività di posizioni differenti vari congiuntamente nel tempo.

4.3 Confronto con il lavoro di Ahmadi Moghadam et al.

Il risultato ottenuto è coerente con la motivazione generale del lavoro di Ahmadi Moghadam et al. [1]: le relazioni tra segnali EEG contengono informazione particolarmente utile per distinguere soggetti ADHD e controlli.

Il confronto numerico tra i due lavori deve tuttavia essere svolto con cautela. Gli autori utilizzano lo stesso dataset, ma adottano una pipeline differente descritta in precedenza.

Il loro modello migliore è ottenuto nella banda theta e raggiunge un'accuracy pari al 98.88%, con precision del 98.41%, recall del 98.19% e F1-score del 98.30%. Nel confronto puramente numerico, il modello del paper ottiene quindi un'accuracy superiore al 96% raggiunto dalla Random Forest del presente lavoro. [1]

Non è tuttavia corretto concludere che la CNN sia necessariamente superiore alla Random Forest, perché i due risultati non derivano dallo stesso protocollo di valutazione. Cambiano infatti:

- l'unità di input, costituita da epoche nel paper e da una rappresentazione globale di 60 secondi nel presente lavoro;
- le misure di connettività, poiché il paper combina Pearson e PLV, mentre il presente progetto utilizza soltanto Pearson;
- la rappresentazione dei dati, trattata come matrice bidimensionale dalla CNN e come vettore di feature nei modelli tradizionali;
- il preprocessing e l'ottimizzazione del modello;
- la suddivisione in training, validation e test.

Il paper “vince” quindi in termini di accuracy riportata, mentre il presente approccio presenta vantaggi differenti: è più semplice, richiede minori risorse computazionali e permette di identificare direttamente le connessioni che contribuiscono alla classificazione.

Un risultato interessante è che, anche utilizzando soltanto la correlazione di Pearson e classificatori relativamente semplici, la functional connectivity raggiunge prestazioni elevate. Ciò suggerisce che una parte consistente dell'informazione discriminante sia già presente nella covariazione lineare tra i segnali. Non è però possibile stabilire, sulla base del confronto attuale, quanto l'ulteriore vantaggio del paper dipenda dal PLV, dalla segmentazione in epoche, dalla CNN, dal modulo di attention o dallo specifico split dei dati.

Un confronto realmente informativo richiederebbe di applicare entrambe le pipeline allo stesso preprocessing, agli stessi soggetti di training e test e alle stesse unità di analisi, eseguendo anche un'analisi di ablazione tra Pearson, PLV e mappe fuse.

4.4 Criticità e limitazioni

La principale limitazione riguarda la numerosità del campione. Il dataset comprende 121 soggetti e il test set soltanto 25 partecipanti. In un campione di queste dimensioni, un singolo errore modifica l'accuracy di quattro punti percentuali. Il valore del 96% corrisponde infatti a 24 soggetti correttamente classificati su 25 e deve essere considerato una stima con elevata incertezza.

Un ulteriore elemento di cautela è la differenza tra la performance ottenuta durante il tuning e quella osservata sul test. La Random Forest sulla connettività ha raggiunto una balanced accuracy media in cross-validation pari a circa 0.707, ma una balanced accuracy di 0.958 sul test. Il forte miglioramento sul test può indicare che lo specifico insieme di 25 soggetti sia risultato particolarmente favorevole. Non costituisce quindi una prova sufficiente di generalizzazione.

Il problema è inoltre fortemente ad alta dimensionalità: il modello di connettività utilizza 724 predittori, mentre il training set contiene circa 96 soggetti. Il numero di feature è quindi molto maggiore del numero di osservazioni, condizione che aumenta il rischio di overfitting e rende più instabile l'importanza attribuita alle singole connessioni.

La feature importance della Random Forest è basata sulla riduzione dell'impurità e può essere distribuita tra feature correlate. Non indica la direzione dell'effetto, non rappresenta un'associazione causale e non garantisce che le stesse connessioni risulterebbero importanti in un campione differente.

La correlazione di Pearson rappresenta una misura di connettività funzionale statica e a ritardo nullo. È sensibile alla conduzione di volume, alla presenza di sorgenti comuni e alla scelta del riferimento EEG. Una correlazione elevata tra due elettrodi non implica quindi necessariamente una comunicazione funzionale diretta tra le regioni corticali sottostanti.

La connettività è stata riassunta su un unico intervallo di 60 secondi. Questa scelta produce una rappresentazione stabile a livello del soggetto, ma elimina le variazioni temporali che possono avvenire durante il compito. I bambini osservavano immagini successive, ma il dataset non contiene marcatori relativi alla presentazione degli stimoli o alle risposte. Non è quindi possibile stabilire se una determinata configurazione di connettività sia associata a uno specifico momento del task.

Anche il preprocessing presenta alcune limitazioni. Il dataset non dispone di canali EOG separati e la selezione delle componenti oculari è stata effettuata automaticamente mediante ICLabel. Con soltanto 19 canali, la separazione ICA ha inoltre una risoluzione limitata. Possono quindi rimanere artefatti residui oppure essere rimosse componenti contenenti una combinazione di attività artefattuale e neurale.

I dati provengono infine da un singolo centro e da una sola condizione sperimentale. Non sono disponibili informazioni sufficientemente dettagliate per studiare separatamente sottotipi di ADHD, gravità dei sintomi, qualità del sonno, prestazione al compito o risposta ai singoli stimoli. I risultati non possono pertanto essere generalizzati automaticamente ad altre età, condizioni di riposo, task differenti o popolazioni cliniche.

4.5 Sviluppi futuri

Un primo sviluppo riguarda l'introduzione di una Logistic Regression con regolarizzazione L_1 . A differenza della penalizzazione L_2 utilizzata nel presente lavoro, la penalizzazione L_1 può portare esattamente a zero i coefficienti meno informativi:

$$\lambda \sum_{j=1}^p |w_j|. \quad (78)$$

Questo permetterebbe di svolgere contemporaneamente classificazione e selezione delle feature, ottenendo un insieme più sparso e interpretabile di connessioni. Tale approccio sarebbe particolarmente utile per le 724 feature di functional connectivity. Poiché molte connessioni sono correlate, sarebbe inoltre opportuno confrontare L_1 con Elastic Net, che combina penalizzazione L_1 e L_2 e può produrre una selezione più stabile dei gruppi di feature ridondanti.

La selezione della forza di regolarizzazione e, nel caso di Elastic Net, del rapporto tra le due penalizzazioni dovrebbe essere eseguita mediante nested cross-validation. Sarebbe inoltre utile valutare la stabilità delle feature selezionate ripetendo la procedura su più suddivisioni del campione.

Un secondo sviluppo riguarda l'utilizzo di modelli più profondi per le feature spettrali. Le potenze di banda sono state attualmente riassunte in un vettore e analizzate con modelli tabellari. Una rete neurale potrebbe invece ricevere:

- mappe canale $\times$ frequenza della PSD;
- rappresentazioni topografiche separate per banda;
- sequenze temporali di potenze calcolate su finestre successive;
- direttamente segmenti del segnale EEG.

Una CNN potrebbe apprendere pattern spaziali tra elettrodi vicini, mentre una rete temporale, una LSTM o un Transformer potrebbero modellare l'evoluzione delle oscillazioni durante il task. Con un campione di soli 121 soggetti, tali modelli richiederebbero però una regolarizzazione molto forte, una validazione subject-wise e, idealmente, un dataset più ampio o tecniche di transfer learning.

Un terzo sviluppo consiste nel riprodurre più direttamente la pipeline di Ahmadi Moghadam et al., costruendo separatamente:

1. mappe basate soltanto sulla correlazione di Pearson;
2. mappe basate soltanto sul Phase-Locking Value;
3. mappe fuse Pearson-PLV.

Le tre rappresentazioni potrebbero essere valutate sia con i modelli tradizionali sia con una CNN con attention, mantenendo identici preprocessing, split dei soggetti e metriche. Un'analisi di ablazione permetterebbe così di stabilire quale contributo derivi dalla misura di fase, quale dalla fusione e quale dall'architettura profonda.

Un ulteriore sviluppo particolarmente rilevante è rappresentato dalla dynamic functional connectivity. Nel presente lavoro ogni connessione è descritta da un unico coefficiente calcolato sull'intero intervallo di 60 secondi:

$$r_{ij}^{\text{static}} = \text{corr}(x_i(t), x_j(t)). \quad (79)$$

La connettività dinamica può invece essere calcolata su finestre temporali successive, eventualmente sovrapposte:

$$r_{ij}^{(w)} = \text{corr}(x_i(t \in w), x_j(t \in w)), \quad (80)$$

dove w identifica una finestra temporale.

Per ogni connessione sarebbe quindi possibile estrarre non soltanto il valore medio, ma anche la variabilità, il range, la velocità di cambiamento e la persistenza nel tempo. Le matrici ottenute nelle diverse finestre potrebbero inoltre essere raggruppate in stati ricorrenti di connettività mediante clustering o Hidden Markov Models. Si potrebbe così verificare se ADHD e controlli differiscano non tanto per una rete media, quanto per la frequenza con cui raggiungono determinati stati o per la stabilità delle configurazioni funzionali.

La dynamic functional connectivity sarebbe particolarmente adatta a un compito attento, nel quale il livello di concentrazione e la risposta allo stimolo possono cambiare nel corso della registrazione. La mancanza di marcatori degli eventi impedirebbe comunque di associare direttamente gli stati a immagini o risposte specifiche.

Altri sviluppi potrebbero comprendere misure meno sensibili alla conduzione di volume, come Phase-Lag Index, weighted Phase-Lag Index o imaginary coherence, e l'estrazione di metriche di teoria dei grafi, quali forza dei nodi, clustering coefficient, efficienza, modularità e centralità.

Infine, la priorità metodologica dovrebbe essere la validazione dei risultati. Sarebbe necessario utilizzare repeated nested cross-validation, stimare intervalli di confidenza delle metriche, applicare permutation test alla performance e verificare la pipeline su un dataset esterno. Solo dopo una validazione indipendente sarebbe possibile valutare se le configurazioni di connettività osservate rappresentino pattern riproducibili associati all'ADHD.

4.6 Conclusione generale

Nel complesso, il progetto mostra che il segnale EEG contiene informazione utile per distinguere i due gruppi, ma che tale informazione dipende fortemente dalla rappresentazione adottata.

Le potenze spettrali e il theta/beta ratio evidenziano alcune differenze, ma non descrivono un pattern semplice e universale. In particolare, il TBR non risulta maggiore negli ADHD e, nonostante fornisca prestazioni moderate nella classificazione, non può essere interpretato come biomarcatore diagnostico autonomo. Questo risultato è coerente con le conclusioni della meta-analisi di Arns et al. [2].

La functional connectivity produce invece una separazione molto più marcata, suggerendo che, durante il compito di attenzione visiva, l'organizzazione congiunta dell'attività EEG sia più informativa della sola potenza locale. Il risultato non identifica una singola connessione responsabile della classificazione, ma un pattern distribuito che coinvolge soprattutto connessioni centro-parietali, fronto-centrali e occipito-parietali nelle bande beta, alpha e theta.

Il contributo principale del lavoro non consiste quindi nell'individuazione di un nuovo marker diagnostico, ma nel mostrare che la scelta della rappresentazione del segnale può

essere più determinante della complessità del classificatore. Prima di attribuire a questi risultati un significato clinico, sarà tuttavia necessario verificarne la stabilità su campioni più ampi, split ripetuti e dataset indipendenti.

Riferimenti bibliografici

- [1] Elham Ahmadi Moghadam, Farhad Abedinzadeh Torghabeh, Seyyed Abed Hosseini, and Mohammad Hossein Moattar. Improved adhd diagnosis using eeg connectivity and deep learning through combining pearson correlation coefficient and phase-locking value. *Neuroinformatics*, 22(4):521–537, 2024.
- [2] Martijn Arns, C. Keith Conners, and Helena C. Kraemer. A decade of eeg theta/beta ratio research in adhd: A meta-analysis. *Journal of Attention Disorders*, 17(5):374–383, 2013.